DOI:10.13475/j.fzxb.20230704201

基于姿态嵌入机制和多尺度注意力的单张着装图像视频合成

陆寅雯[1], 侯 珏[1,2,3], 杨 阳[1,2], 顾冰菲[1], 张宏伟[4], 刘 正[2,3,5]

(1. 浙江理工大学 服装学院, 浙江 杭州 310018; 2. 浙江省服装工程技术研究中心, 浙江 杭州 310018;
3. 浙江理工大学 丝绸文化传承与产品设计数字化技术文化和旅游部重点实验室, 浙江 杭州 310018;
4. 西安工程大学 电子信息学院, 陕西 西安 710043; 5. 浙江理工大学 国际教育学院, 浙江 杭州 310018)

摘 要 基于单张着装图像生成视频在虚拟试衣和三维重建等领域有重要应用,但现有方法存在生成帧之间动作不连贯、生成视频质量差、人物服装细节缺失等问题,为此提出一种基于姿态嵌入机制以及多尺度注意链接的生成对抗网络模型。首先采用位置嵌入方法,对相邻帧间动作建模,然后针对每个分辨率尺度的特征添加注意力链接,同时在训练过程中输入人物解析图像,最后在服装视频合成数据集的测试集合上进行结果验证。结果表明:本文模型比当前单张着装图像生成视频主流模型在定性结果与定量结果指标上均有所提高,其中峰值信噪比和运动矢量分别为20.89和0.108 4,说明本文模型能够有效提高视频生成的质量与帧间动作的稳定性,为着装人物视频合成提供了新模型。

关键词 生成对抗网络; 视频合成; 深度学习; 姿态嵌入; 注意力机制; 着装图像; 虚拟试衣

中图分类号:TS 942.8 **文献标志码**:A

互联网的快速普及使得短视频成为现代社会中重要的信息沟通媒介,然而,剪辑个性化视频是一项耗时且复杂的任务,尤其是针对人物进行视频合成。随着深度学习技术的发展,基于图像生成视频的人工智能技术只需通过1张标准姿态下的源人物图片以及1个带有目标动作的视频,便能合成以源人物做目标动作的新视频。这种技术在虚拟试衣[1]、特效生成、三维重建[2]等领域具有广泛的应用前景。然而,由于视频合成需要考虑时间序列中相邻帧之间的连续性和稳定性,且输入图像的已知信息有限,因此基于人物图像的视频合成已成为备受关注且具有挑战性的研究方向。

生成对抗网络(generative adversarial networks, GAN)的出现使基于图像的视频生成任务产生了高质量的结果。Cai等[3]采用基于姿态估计的2个阶段生成框架,第1阶段从随机噪声中生成人体姿态序列,第2阶段在给定条件图像的情况下,将生成的人体姿态序列从姿势空间映射到像素空间,从而解决了视频生成任务中人物与姿态的不适定问题。然而,只对人物姿态单独建模会导致动态人物与静态视频内容相互干扰,引起视频帧出现模糊或不连贯的现象。Villegas等[4]将卷积神经网络和LSTM模型进行结合,独立捕捉图像的空间布局与时间动态,并通过对运动和内容的独立建模,以无监督方式将前一阶段的运动特征和内容特征组合解码来生成下一帧。Walker等[5]融合VAE与GAN模型,并以渐进的方式处理内容和动作。该模型首先使用变分自编码器预测未来可能的人体运动姿态,再以预测姿态作为GAN的输入条件,对像素空间中的未来帧进行预测。该方法通过将姿势的结构化空间作为中间信息,避开GAN直接生成视频像素时人物姿态存在的不合理问题,但无法保证视频序列的时间平滑性。

以上方法均属于无监督学习。此外基于图像生成视频任务也可使用有监督学习。Mathieu等[6]首次尝试在视频生成领域使用有监督的对抗训练,多尺度的生成网络以前一帧为条件预测连贯的未来帧。但该方法并未针对人物姿态进行建模,无法还原精确的人物运动。Hu等[7]使用运动笔画作为控

收稿日期:2023-07-18 **修回日期**:2024-01-08

基金项目:国家自然科学基金青年科学基金项目(61803292);浙江省科技计划项目(2023C03181);浙江理工大学科研启动基金项目(21072325-Y)

第一作者:陆寅雯(1998—),女,硕士生。主要研究方向为服装虚拟试衣技术。

通信作者:刘正(1981—),男,教授,博士。主要研究方向为数字化服装技术。E-mail:koala@zstu.edu.cn。

中国知网 https://www.cnki.net

制信号为输入图像中的移动物体提供方向,通过一个循环网络结构按照这些方向生成视频序列。该方法虽然能够从单张图像和运动笔画序列中生成任意时刻的动作帧,但无法保留复杂的人物细节。Dong 等[8]通过 4 个平行的编码器对目标人物图像、服装图像、过去生成的帧序列和关节点信息序列进行编码,并使用 2 个解码器分别解码光流以及服装。Zhu 等[9]试图将注意力机制引入该任务,通过一系列的姿势注意传递块,对每个部分的姿态特征执行局部传递,逐步生成目标帧。虽然上述研究方法在图像合成视频的任务中取得了一定的效果,但由于没有考虑到时间序列上相邻 2 帧之间动作的平滑性,导致姿态解析误差较大。

近年来,位置嵌入思想被广泛应用于视频领域。在视频处理中,可将每个图像帧视为 1 个向量,并使用位置嵌入来表示每个图像帧的相对位置,有助于模型捕捉图像帧之间的时序信息。Zhao 等[10]通过级联变换器层捕捉每个视频帧中人体关节的空间关系和帧间的人体动作变化。现有方法通常自关注时间序列上的所有帧,使运算量增加,且不同帧之间的稳定性较差。

为解决单张图像生成视频中存在的人物细节外观丢失、相邻帧间动作平滑性差、生成视频质量低等问题,本文提出了一种基于姿态嵌入机制以及多尺度注意力机制的视频生成框架 EBDGAN。引入改进的姿态嵌入模块对相邻帧之间动作变化建模,减少数据参数量的同时增加相邻帧之间的稳定性;在编码器以及解码器的每个分辨率尺度上都引入注意力链接,提高对视频中动作特征的提取能力,进一步提高视频生成质量;加入人物解析图像辅助网络生成,加强服装特征的表征能力,保证生成人物外观的合理性与完整性。本文模型在训练和测试服装走秀视频高清数据集[8]上取得了较好的效果,与视频姿态迁移任务最新模型相比峰值信噪比 PSNR 提高了 17%,运动矢量提高了 7.2%。

1 模型结构

本文设计了一种基于姿态嵌入模块以及多尺度注意力机制的视频生成对抗网络模型 EBDGAN,其结构如图 1 所示。该模型由 3 个部分组成,包括姿态嵌入模块、生成器模块、判别器模块。其中,生成器模块包含姿态编码器 E_P,全局编码器 E_g 和全局解码器 D_G。E_P 和 E_G 具有相同的网络结构,其目的是对姿态以及人物图像进行特征提取。全局解码器 D_G 利用卷积运算与上采样运算,将人物特征图进行尺寸与信息还原。在该过程中,上采样运算前均有注意力链接以及姿态嵌入模块将姿态信息以及视频序列信息融入视频合成。全局编码器 E_g 的输入为标准姿态下的人物图像 I_s 以及人物解析图像 M_s,姿态编码器 E_P 的输入为标准人物姿态的热力图 P_s 以及第 k 帧对应的目标人物姿态热力图 P_t^k。

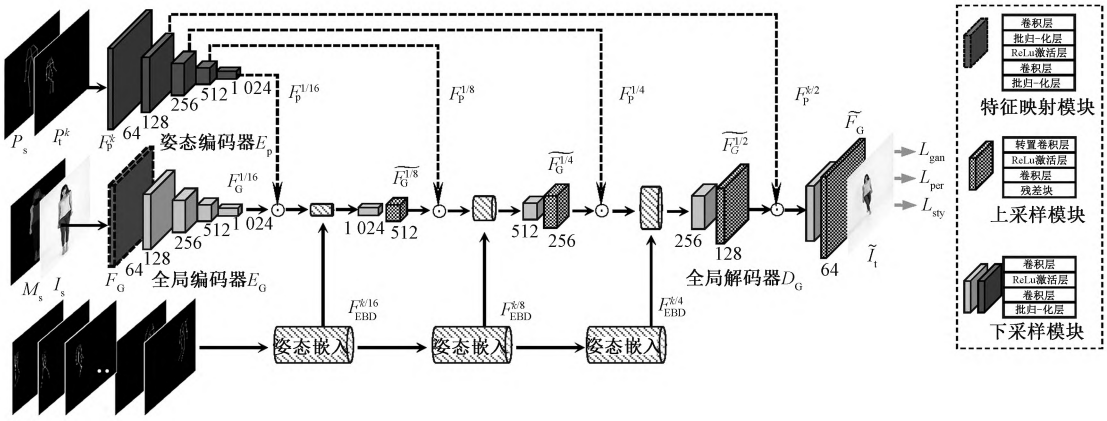

图 1 EBDGAN 网络结构整体示意图

Fig. 1 Network structure of EBDGAN

在训练过程中,编码器先通过特征映射模块将输入映射到尺寸为 $(H \times W \times C)$ 的初始特征 F_G 中,其中 H 为输入图像的高,W 为输入图像的宽,C 为输出特征的通道数。特征映射模块包含卷积层(尺寸为 3,步长为 1)、批归一化和 ReLu 激活层。随后将初始特征 F_G 输入编码器中 4 个连续的下采样模块,每个上采样模块遵循卷积层(尺寸为 4,步长为 2)、池化层、ReLu 激活层和残差块的结构,每经过 1 次下采样模块,初始特征 F_G 的尺寸变为原来的 1/2,通道数变为 2 倍。最终,可以

中国知网 https://www.cnki.net

通过 E_g 与 E_P 获得图片特征映射 $F_G^{1/2n}$ 与姿态特征映射 $F_P^{k/2n}$,其尺寸为 $\frac{H}{2^n}\times\frac{W}{2^n}\times C^{2n}$,$n=4$。编码过程可用下式表示:

$$F_P^{k/2n}=E_p(P_s,P_t^k)$$
$$F_G^{k/2n}=E_p(M_s,I_s)$$

解码结构共分为 4 个阶段,每个阶段 D_G 均首先通过注意力机制将姿态特征映射 $F_p^{k/2n}$ 引入图像特征映射 $F_G^{1/2n}$ 的解码运算,在本文模型中 n 取 1、2、4、8,再与姿态嵌入模块 EBD 提取的第 k 帧相邻姿态差异特征 $F_{EBD}^{k1/2n}$ 进行特征激活,随后通过上采样模块将尺寸扩大为原来的 2 倍,通道数变为原来的 1/2,该上采样模块包括转置卷积层、ReLu 激活层、卷积层(尺寸为 4,步长为 2)和残差块,重复以上操作直到 $\tilde{F}_G^{1/2n}$ 的形状为($H\times W\times C$)。最后对 $\tilde{F}_G^{1/2n}$ 进行卷积核为 1×1 的逐点二维卷积运算,将特征空间映射到($H\times W\times 3$)的维度后使用 Tanh 激活函数得到最终生成图像 $\tilde{I}_t\in \boldsymbol{R}^{H\times W\times 3}$。解码过程可用下式表示:

$$\tilde{F}_G^{1/2n}=D_G((F_P^{k/2n}\odot F_G^{1/2n})\otimes F_{EBD}^{k/2n})$$
$$\tilde{I}_t=\mathrm{Tanh}(\mathrm{Conv}(\tilde{F}_G^{1/2n}))$$

式中:⊙为逐元素相乘;⊗为特征图相乘;Tanh 为神经网络中的激活层函数;Conv 为神经网络中的卷积部分。

对于判别器模块,本文使用马尔可夫判别器 PatchGAN[11]。与传统判别器不同,其将输入图像分割成 $N\times N$ 个图像块,N 为图像块数量,每个图像块都输出 1 个真实或假的结果。Patchgan 通过马尔可夫随机场对图像建模来实现纹理损失。为增强高频信息的生成效果,本文判别器通过将(I_s,I_t)标记为真,将(I_s,$\tilde{I}_t$)标记为假,来考虑对图像差异而不是图像本身执行对抗操作。

1.1　姿态嵌入模块

视频生成任务不仅需要考虑生成帧的质量,还需要考虑 2 帧之间稳定性,因此本文提出姿态嵌入模块来进行时间序列上的姿态信息建模,从而提高网络对相邻 2 帧姿态间差异的学习能力,提高模型对位置序列的理解。其结构如图 2 所示。

将 K 时刻的目标姿态坐标 $P_t^k\in \boldsymbol{R}^{2m\times 1\times 1}$ 以及 $K-1$ 时刻的姿态坐标 $P_t^{k-1}\in \boldsymbol{R}^{2m\times 1\times 1}$ 拼接成一维数组 $L_t^k\in \boldsymbol{R}^{2m\times 2\times 1}$,其中,$m$ 为姿态关节点数量。随后位置编码器 E_{EBD} 通过姿态映射模块将 L_t^k 映射到一个低维向量中,如以下公式表示:

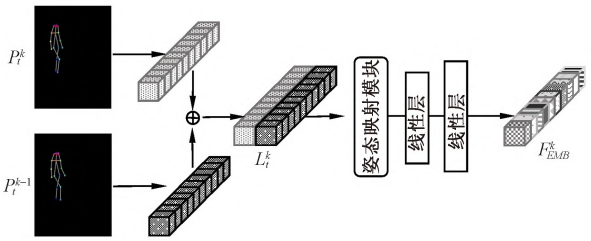

图 2　姿态嵌入模块结构示意图

Fig. 2　Network structure of pose embedding

$$F_{EBD(i)}^K=\begin{cases}\sin(L_t^k+L_t^{k-1})_i, i\in[1,m]\\ \cos(L_t^k+L_t^{k-1})_i, i\in[m+1,2m]\end{cases}$$

式中:i 为向量数组的索引;m 为关节点数量,在本文模型中 m 取 18。

通过将姿态信息编码为 1 个包含正弦函数和余弦函数的向量后,再通过 2 次线性操作获得包含相邻帧信息的姿态特征 F_{EBD}^K。在解码阶段将 F_{EBD}^K 与注意力运算后的特征 I_G 进行特征激活运算并输入全局解码器解码。激活运算通过 F_{EBD}^K 对特征通道赋予权重,在保留姿态信息的情况下迫使网络注意相邻帧之间的动作变化幅度,从而提高模型对姿态位置的表达能力,激活运算由以下公式表示。

$$\tilde{F}_G^k=I_G\odot F_{EBD}^k+F_{EBD}^k$$

1.2　多尺度注意力链接

人物姿态转移的过程本质上是将像素从标准姿态的位置迁移到目标既定区域。因此,本文通过在每个分辨率级别中构建注意力链接来显示表达网络的采样位置以及生成位置引导姿态转移。设注意力掩码表示为 M_t^k,M_t^k 由姿态编码器的输出 F_p^k,通过 Sigmoid 激活获得,M_t^k 的值在 0~1 之间,其响应值越高代表该位置特征具有更高权重。将 M_t^k 与图像编码器提取的特征 F_G 进行逐元素相乘获得更新后的特征 I_G,并通过 EBD 模块进行特征激活,作为下一次解码器的输入。本文在每个解码器之前都重复该操作直至还原图像。该过程可用公式表示:

$$M_t^k=\mathrm{Sigmoid}(F_P^k)$$
$$I_G=M_t^k\odot D_G(\tilde{F}_G^{k-1})+\tilde{F}_G^{k-1}$$

通过将图片特征与注意力掩码相乘,有效信息被保留,无效信息被抑制。元素乘积后的输出加上原特征构成残差链接[12],有助于保留原图像信息。

1.3　损失函数

本文生成网络的目标是基于单张图像对连续视频进行生成,损失函数的主要用于引导模型对像素信息进行重构,具体包括 L_1 损失、GAN 损失与感知损失。

为保证生成帧的低频正确性,模型使用 L_1 损失

中国知网　https://www.cnki.net

对生成结果进行像素级别的监督,如下所示:

$$L_1 = \frac{1}{m}\sum_{j=1}^{m} \| \tilde{I}_t^{(j)} - I_t^{(j)} \|_1$$

式中:$\tilde{I}_t$ 为生成帧图像;I_t 为目标帧图像。

为进一步提高生成帧的质量,对生成信息的高频分量进行监督,使用带有 PatchGAN[11] 的交叉熵损失函数来惩罚图像之间的分布差异,公式为

$$L_{gan} = \mathbb{E}(\log(1 - D(I_s, \tilde{I}_t))) + \mathbb{E}(\log(D(I_s, I_t)))$$

式中,$\mathbb{E}$ 为特征提取编码器。

perceptual 损失可有效提升生成图像的视觉保真度,通过使用预训练的 VGG19[13] 网络提取特征,监督像素之间的微小差异,保留目标图像的整体视觉内容,公式为

$$L_{per} = \frac{1}{h_i w_i c_i}\sum_{x=1}^{h_i}\sum_{y=1}^{w_i}\sum_{z=1}^{c_i} \| \Phi_i(I_t) - \Phi_i(\tilde{I}_t) \|_1$$

式中:Φ_i 为特征提取编码器;i 为网络特征层的位置,本文选取 VGG19 的第 4 层以及第 9 层特征计算损失以同时监督图像的高频及低频信息。

综上,完整的生成器损失函数可表达为

$$L^G = \lambda_1 L_1 + \lambda_2 L_{gan} + \lambda_3 L_{per}$$

式中,$\lambda_1, \lambda_2, \lambda_3$ 为实验中的超参数,在本文中分别为 2,0.5,5。

本文判别器使用平均 BCE 损失评价输出与目标之间的差异。公式表示为

$$L^D = \frac{1}{2}[L_{BCE}(D(I_s, \tilde{I}_t), 1) + L_{BCE}(D(I_s, \tilde{I}_t), 0)]$$

2 实验和结果分析

本文在 VVT(video virtual try-on)[8] 走秀视频数据集上训练与验证本文模型,并通过定性分析结果与定量分析结果来验证本文方法的先进性与有效性。

2.1 数据集和实验设置

VVT 数据集包含 791 个 8~10 s 的走秀视频,视频均以 30 帧/s 的速度录制,视频每帧的分辨率为 192 像素×256 像素。每个视频都对应 1 件单独的服装图像和穿着该服装的模特标准站姿图像。在数据集分配方面,将数据集划分为 656 个训练视频以及 135 个测试视频,最终训练集包含 159 170 张图像,测试集包含 30 931 张图像。每张图像均使用 SCHP[14] 提取对应的解析图像,SCHP 将人物属性划分为 22 个类别,本文合并其中一些属性以减小数据负荷(例如左手和右手合并为手)最终每个解析图像通过值从 1~15 的单通道矩阵表示。本文使用提取每张图像对应的 18 个人体姿态关节点并编码为 18 个通道的矩阵,每个通道代表对应的人体关节热力图。

本文模型基于深度学习框架 pytorch 实现,所有实验均在 2 块 NVIDIA GeForce RTX 3060ti GPU 上进行,在训练中使用 Xavier[15] 方法初始化所有卷积核。本文模型使用 Adamw 优化器优化生成器和判别器,学习率 $\eta = 0.001$,$\beta_1 = 0.5$,$\beta_2 = 0.999$。一次图像数量设置为 8。模型训练迭代次数达到 120 次后终止。

2.2 定量结果

基于人体姿态生成视频任务可从生成视频质量和视频连续帧之间的稳定性进行评价。使用以下指标对生成结果进行评价:结构相似性 SSIM(structure similarity index metric)[16] 是评价图像亮度、对比度的指标,对图像局部区域较为敏感。学习感知图像相似度 LPIPS(learned perceptual image patch similarity)[17] 计算感知域中生成的图像与真实图像之间的重建误差。峰值信噪比 PSNR(peak signal-to-noise ratio)[18] 也被广泛用于衡量生成图像的质量,其用于衡量均方误差来给出整体评价和结构,信噪比越高表示图像噪声越小,生成图像的质量越好。相较于图像,视频连续帧之间的差异也会显著影响视频质量,因此引入运动矢量 MV(motion vector)[18],该指标是相邻 2 帧之间的运动矢量大小和方向。在视频稳定性方面,MV 越大,表示相邻 2 帧之间的移动越小,即视频稳定性越高。将 EBDGAN 模型与 PISE[19],PATN[9],CASD[20] 进行比较,以证明模块的有效性。

不同模型训练 VTT 数据集的定量比较结果如表 1 所示。可看出,EBDGAN 模型在 LPIPS 值、PSNR 值以及 MV 值上都获得了更好的结果。LPIPS 值和 PSNR 值表明 EBDGAN 的生成结果在颜色以及结构上更接近原视频,这归因于本文使用的感知损失。从 MV 值可以得出 EBDGAN 从单张图像生成的视频相邻 2 帧之间移动更小,因此帧相似度更高,视频整体更加稳定,这归因于 EBDGAN 的姿态嵌入模块对相邻帧进行建模,也验证该模块的有效性。虽然 SSIM 值的评分略低于 CASD 模型,但本文方法保留了更多的纹理细节以及合理的人物体型,且 CASD 引入光流数据,增加了计算成本,EBDGAN 仅需图像以及姿态信息作为输入,更加高效。

表 1 不同模型在 VTT 数据集上的定量结果

Tab. 1 Quantitative results of different models

模型	SSIM 值↑	LPIPS 值↓	PSNR 值↑	MV 值↑
PISE[19]	0.847	0.187	20.60	0.096 8
PATN[9]	0.851	0.171	20.63	0.094 2
CASD[20]	0.863	0.176	20.72	0.101 0
EBDGAN	0.855	0.1619	20.89	0.108 4

注:↑表示该值越大效果越好;↓表示该值越小效果越好。

中国知网 https://www.cnki.net

2.3　定性结果

本文选取视频生成效果较优的模型,提取不同时刻的视频帧进行对比,结果如图 3 所示。可看出,EBDGAN 可在形状以及颜色方面生成最接近原始视频的结果。在人物离镜头较远的视频帧中,EBDGAN 保留了头发和鞋子的细节(见图 3(c))。在人物离镜头较近的视频帧中,EBDGAN 的正面服装图像保留了衣领与下摆部分(见图 3(b)的领口以及图 3(e))的下摆部分。当视频中人物转身时,EBDGAN 并未导致视频中的人出现怪异的姿势或者身体一部分消失,反而生成了更加合理的身体形状。在同样的训练策略下,PISE 在人物转身时产生了身体部位的缺失,PISE 生成的图像过于平滑。综上所述,本文模型在 VTT 数据集上取得较好的效果。

图 3　各模型在 VTT 数据集上的定性结果

Fig. 3　Qualitative results of each model. (a) Target poses; (b) Results of PISE; (c) Results of PATN; (d) Results of CASD; (e) Results of EBDGAN; (f) Groundtruth

2.4　消融实验

为证明本文所提出的姿态嵌入模块、多尺度注意力链接以及服装解析图像的有效性,对模型进行变体设计并进行消融实验。第 1 个变体 EBDGAN-0,删除了姿态嵌入模块以及交叉注意力机制模块,服装解析图像不作为辅助输入。第 2 个变体 EBDGAN-1 将服装解析图像作为辅助收入,网络保留了每个分辨率上的注意力链接。第 3 个变体 EBDGAN-2 保留了姿态嵌入模块但跳过了注意链接。对于第 4 个变体,是完整的 EBDGAN 模型。每个变体网络的训练都遵循相同的配置,在相同的训练数据进行 130*K* 次迭代优化。定量分析结果如表 2 所示。

表 2　消融实验在 VTT 数据集上的定量结果

Tab. 2　Quantitative results of ablation experiments

方法	SSIM 值↑	LPIPS 值↓	PSNR 值↑	MV 值↑
EBDGAN-0	0.830	0.183	20.45	0.080 7
EBDGAN-1	0.846	0.168	20.52	0.097 0
EBDGAN-2	0.847	0.177	20.16	0.104 1
EBDGAN	0.855	0.162	20.89	0.108 4

注:↑表示该值越大效果越好,↓表示该值越小效果越好。

通过评估每个模型的 SSIM 值、LPIPS 值、PSNR 值以及 MV 值发现,原始 EBDGAN 达到最好的分数。完整的模型可高效利用输入图像的姿态信息和特征来指导视频生成。屏蔽任何一个网络组件都会导致模型性能下降。EBDGAN-1 的结果表明多尺度的注意力链接可帮助网络生成分布更合理的图像。从 EBDGAN-2 的 MV 值表明,当添加姿态嵌入模块后,相邻 2 帧之间移动更小,视频的稳定性更高。定性分析结果如图 4 所示。

图 4　消融实验在 VTT 数据集上的定性结果

Fig. 4　Qualitative results of ablation experiments. (a) Target poses; (b) Results of EBDGAN-0; (c) Results of EBDGAD-1; (d) Results of EBDGAD-2; (e) Results of EBDGAN; (f) Groundtruth

中国知网　https://www.cnki.net

从图 4 可看出,当屏蔽掉所有模块时,模型生成的结果会过于平滑,当目标姿态与原图姿态差异过大时,无法生成合理的人体形状(例如第 2 行右边图像)。当加入多尺度注意力链接后,模型在表达服装外观上的性能显著提升(例如第 2 行左边服装部分),这是由于多尺度注意力链接帮助网络进一步感知图像的高频信息。当只有姿态嵌入模块时,虽然生成了不合理的颜色,但是在面对大幅度的姿态变化时,模型能够生成更加合理的人体形状。

综上所述,通过消融实验的定量和定性结果可知,完整的 EBDGAN 的模型可获得最好的结果,表明在基于单张图像生成视频的任务中。引入 2 帧之间姿态差异的建模以及多尺度的注意力链接可显著提高图像的视觉效果以及指标。

3 结 论

本文提出了一种基于姿态嵌入机制和多尺度注意力链接的单张图像生成视频的方法。该方法通过姿态嵌入模块对时间序列上相邻帧之间姿态建模,减小参数量的同时保证相邻帧之间动作的连贯性。通过多尺度注意力链接,提高特征提取效率,进一步提高视频生成质量。使用人物解析图像作为辅助输入,加强人物服装的表现能力。本文方法在公开数据集上进行实验与验证,结构相似性值为 0.855,感知相似度值为 0.162、峰值信噪比为 20.89、运动矢量为 0.108 4。消融实验证明本文模块能够帮助网络在视频生成任务中实现更好的性能。对比实验证明了本文方法生成视频的稳定性更好,人物细节更真实。

目前本文模型在公开数据集上进行实验,未来考虑采集复杂背景下的人物视频数据集,并对现有网络结构进行优化,以适用更多情况下的视频生成任务。 FZXB

参考文献:

[1] 张颖,刘成霞.生成对抗网络在虚拟试衣中的应用研究进展[J].丝绸,2021,58(12):63-72.
ZHANG Yin, LIU Chengxia. Research progress on the application of generative adversarial network in virtual fitting[J]. Journal of Silk, 2021,58(12):63-72.

[2] 王晨麟,赵正,张涛,等.面向微运动视频的三维重建[J].计算机系统应用, 2022, 31(7):298-306.
WANG Chenglin, ZHAO Zheng, ZHANG Tao, et al. Iterative reconstruction for micro motion video [J]. Computer System Applications, 2022, 31(7): 298-306.

[3] CAI H, BAI C, TAI Y, et al. Deep video generation, prediction and completion of human action sequences[C]//Proceedings of the European conference on computer vision (ECCV). Berlin: Springer-Verlag, 2018: 366-382.

[4] VILLEGAS R, YANG J, HONG S, et al. Decomposing motion and content for natural video sequence prediction[C]//5th International Conference on Learning Representations (ICLR). Addis Ababa: International Conference on Learning Representations, 2017:1-22.

[5] WALKER J, MARINO K, GUPTA A, et al. The pose knows: video forecasting by generating pose futures[C]//Proceedings of the IEEE International Conference On Computer Vision. New York: IEEE Communications Society, 2017: 3332-3341.

[6] MATHIEU M, COUPRIE C, LECUN Y. Deep multi-scale video prediction beyond mean square error[C]// 4th International Conference on Learning Representations (ICLR). Addis Ababa: International Conference on Learning Representations, 2016:1-14.

[7] HU Q, WALCHLI A, PORTENIER T, et al. Learning to take directions one step at a time [C]//2020 25th International Conference on Pattern Recognition (ICPR). Montreal: IEEE Communications Society, 2020:1-8.

[8] DONG H, LIANG X, SHEN X, et al. Fw-gan: flow-navigated warping gan for video virtual try-on [C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. New York: IEEE Communications Society, 2019: 1161-1170.

[9] ZHU Z, HUANG T, SHI B, et al. Progressive pose attention transfer for person image generation [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Communications Society, 2019: 2347-2356.

[10] ZHAO Q, ZHENG C, LIU M, et al. PoseFormerV2: exploring frequency domain for efficient and robust 3D human pose estimation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Communications Society, 2023: 8877-8886.

[11] ISOLA P, ZHU J Y, ZHOU T, et al. Image-to-image translation with conditional adversarial networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. New York: IEEE Communications Society, 2017: 1125-1134.

[12] HE K, ZHANG X, REN S, et al. Deep residual learning for image recog-nition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. New York: IEEE Communications Society, 2016: 770-778.

[13] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[C]//3rd International Conference on Learning Representations (ICLR). Addis Ababa: International Conference on Learning Representations, 2015:1-14.

[14] LI P, XU Y, WEI Y, et al. Self-correction for human parsing[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 44(6): 3260-3271.

[15] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization [C]//International Conference on Learning Representations. Addis Ababa: International Conference on Learning Representations, 2018:23-44.

[16] WANG Z, BOVIK A C, SHEIKH H R, et al. Image

中国知网 https://www.cnki.net

quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.

[17] ZHANG R, ISOLA P, EFROS A A, et al. The unreasonable effectiveness of deep features as a perceptual metric [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. New York: IEEE Communications Society, 2018: 586-595.

[18] HUYNH Q, GHANBARI M. Scope of validity of PSNR in image/video quality assessment [J]. Electronics letters, 2008, 44(13): 800-801.

[19] ZHANG J, LI K, LAI Y K, et al. Pise: Person image synthesis and editing with decoupled GAN [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Communications Society, 2021: 7982-7990.

[20] ZHOU X, YIN M, CHEN X, et al. Cross attention based style distribution for controllable person image synthesis [C]//Computer Vision - ECCV 2022: 17th European Conference. Berlin: Springer-Verlag, 2022: 161-178.

Single dress image video synthesis based on pose embedding and multi-scale attention

LU Yinwen[1], HOU Jue[1,2,3], YANG Yang[1,2], GU Bingfei[1], ZHANG Hongwei[4], LIU Zheng[2,3,5]

(1. *School of Fashion Design & Engineering, Zhejiang Sci-Tech University, Hangzhou, Zhejiang* 310018, *China*; 2. *Apparel Engineering Research Center of Zhejiang, Hangzhou, Zhejiang* 310018, *China*; 3. *Key Laboratory of Silk Culture Inheritance and Product Design Digital Technology, Ministry of Culture and Tourism, Zhejiang Sci-Tech University, Hangzhou, Zhejiang* 310018, *China*; 4. *School of Electronic Information, Xi'an Polytechnic University, Xi'an, Shaanxi* 710043, *China*; 5. *School of International Education, Zhejiang Sci-Tech University, Hangzhou, Zhejiang* 310018, *China*)

Abstract

Objective Video generation based on a single dress image has important applications in the fields of virtual try-on and 3-D reconstruction. However, existing methods have problems such as incoherent movements between generated frames, poor quality of generated videos, and missing details of clothing. In order to address the above issues, a generative adversarial network model based on pose embedding mechanism and multi-scale attention links is proposed.

Method A generative adversarial network (EBDGAN) model based on pose embedding mechanism and multi-scale attention was proposed. Pose embedding method was adopted to model adjacent frame actions and improve the coherence of video generated actions, and attention links for each resolution scale feature were added to improve feature decoding efficiency and generate image frame fidelity. Human parsing images were utilized during the training process to improve the clothing accuracy of the synthesized images.

Results The learned perceptual image patch similarity (LPIPS) and peak signal-to-noise-ratio (PSNR) values indicated that the generated results of EBDGAN were closer to the original video in terms of color and structure. From the motion vector (MV), it was seen that the video generated by EBDGAN from a single image moved less between adjacent frames and had higher similarity between the two frames, leading to more stable the overall videos. Although the structure similarity index metric (SSIM) score was slightly lower than (CASD), this method was more efficient as it only requires image and pose information as input. In some frames where the characters were far from the camera, EBDGAN retained the details of hair and shoes. In some frames where the characters are closer to the camera, the front clothing image of EBDGAN retained the collar and hem, such as the collar of the left image in the second row and the hem of the right clothing. When the characters in the video turned around, EBDGAN did not cause the characters in the video to exhibit strange pose or lose some body parts, but instead generated a more reasonable body shape. The results of the ablation experiment showed that the complete model can efficiently utilize the pose information and features of the input image to guide video generation. Blocking any network component will result in a decrease in model performance. The results of EBDGAN-1 indicated that multi-scale attention linking could help networks generate images with more reasonable distribution. The MV of EBDGAN-2 suggested that when the attitude embedding module was added, the relative movement between adjacent frames was smaller, resulting in high video stability.

Conclusion This article proposes a method for generating videos from single images based on pose embedding mechanism and multi-scale attention linking. This method uses the pose embedding module EBD to model the pose

中国知网 https://www.cnki.net

between adjacent frames in the time series, reducing the number of parameters while ensuring the coherence of actions between adjacent frames. By using multi-scale attention linking, the efficiency of feature extraction is improved, further improving the quality of video generation. Using character analysis images as auxiliary input enhances the expressive ability of character clothing. The prosposed method was experimentally validated on a public dataset, with SSIM 0. 855, LPIPS 0. 162, PSNR 20. 89, and MV 0. 108 4. The ablation experiment proves that the model proposed model can help the network achieve better performance in video generation tasks. Comparative experiments have shown that the proposed method offers better stability in generating videos and more realistic character details.

Keywords generative adversarial network; video synthesis; deep learning; pose embedding; attention mechanism; dressing image; virtual try-on

中国知网 https://www.cnki.net