DOI: 10.19398/j.att.202306007

基于生成对抗网络的非织造布二维图像重建

王志禄[1a]，侯　珏[1a,1b,2]，杨　阳[1a,1b]，刘　正[1b,1c]
（1. 浙江理工大学，a. 服装学院；b. 浙江省服装工程技术研究中心；c. 国际时装技术学院，杭州　310018；
2. 武汉纺织大学武汉纺织服装数字化工程技术研究中心，武汉　430073）

摘　要：非织造布纤维结构的准确表征是其性能分析的重要基础。为了解决基于近似模拟的表征结果中纤维形态、结构与真实样本不一致的问题，提出了一种基于生成对抗网络的非织造布二维图像重建方法。使用全自动光学显微镜对非织造布图像进行抓取，并在此基础上构建纤维生成对抗网络（Fiber generation adversarial network，FGAN）对图像样本进行建模。针对高分辨率图像重建时存在的失真问题，采用多尺度训练策略，同时引入权重多样性损失。采用图像质量评估指标 *FID* 作为实验评价指标，分别与 DCGAN、WGAN-GP、BEGAN、PROGAN 等生成模型进行对比实验。结果表明：FGAN 重建的非织造布图像质量更高；消融实验证明，多尺度训练策略与权重多样性损失函数中 *FID* 数值分别降低 24.52%、20.31%。FGAN 模型的提出，使非织造布结构分析摆脱对近似模拟方法的依赖，提供了准确的纤维分布信息，对非织造布的质量评估、性能优化等应用具有重要意义。

关键词：非织造布；孔隙；生成对抗网络；多样性损失；图像重建
中图分类号：TS941.79　　**文献标志码：**A　　**文章编号：**1009-265X(2024)01-0054-10

非织造布是由定向或随机排列的纤维成网加固而成，内部具有复杂的纤维结构。探究纤维集合体的内部结构有助于分析非织造布的力学性能、透气性、过滤性能等特性，为非织造布的设计和应用提供指导[1-3]。

目前，对非织造布的内部结构分析往往采用 CT 设备，该设备成本较高，测试流程复杂。研究人员通常采用参数模拟或分形理论对非织造布的结构进行建模。潘莺等[4]使用计算机生成随机排列的直线来模型熔喷纤网的孔径分布，并与实际的单层熔喷纤网进行对比分析。Simmonds 等[5]基于纤网平面一致性理论，通过多层直线状纤维网叠加构造出非织造布孔隙分布模型。金关秀等[6]以纤维根数、纤维平均直径以及纤维直径变异系数为参数，运用 MatLab 编程对非织造布图像进行建模。上述研究中模拟的纤网虽然与实际的非织造纤网在孔隙率等指标接近，但是其纤维形态呈直线，与实际的纤维卷曲形态相差甚远。杨旭红[7]利用随机分形曲线模拟纤维的卷曲形态，进而模拟出各种类型的非织造纤维网。高贵[8]将分形理论与图像处理技术结合，提出了分形维数与纤维网的随机程度、孔隙率成正相关的理论模型。分形理论解决了纤维形态难以表达的问题，但该理论只是抽象地对非织造结构进行概括性描述，无法具象地重构真实的非织造布结构。Wang 等[9]基于生成对抗网络对拆分后的单根纤维图像进行重建，并使用重建后的单根纤维在一定空间内随机分布重构出非织造布的三维结构。然而，由于纤维之间存在相互作用力，拆分后的纤维失去力的作用后形态发生变化，基于此重建出的纤维图像并不能反映非织造布结构的真实纤维状态。

上述方法模拟生成的纤网结构形态与真实情况有着较大的差异，容易造成非织造布性能评估的误差。基于体视学理论，使用二维图像结构的统计信息能够分析非织造布的内部结构[10]。为了重建出

收稿日期：2023-06-02　**网络出版日期：**2023-08-04
基金项目：武汉纺织服装数字化工程技术研究中心开放基金项目（SZH202201）；嘉兴市重点研发计划项目（2021BZ10001）
作者简介：王志禄（1998—），男，江西信丰人，硕士研究生，主要从事计算机视觉方面的研究。
通信作者：刘正，E-mail：koala@zstu.edu.cn

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

与真实纤维结构一致的非织造布二维图像，构建基于多尺度训练策略的纤维生成对抗网络（Fiber generation adversarial network，FGAN），通过对非织造布显微图像样本进行训练学习，可实现真实的非织造布纤维结构图像重建。重建出高质量且真实的非织造布纤维图像能够用于非织造布立体结构的建模和仿真。

1　非织造布图像生成模型

1.1　生成对抗网络

生成对抗网络（Generate adversarial networks，GANs）是一种无需大量标注数据就能学习图像深度信息的方法[11]。生成对抗网络由生成器 G 和判别器 D 两部分组成，其模型结构如图 1 所示。生成器 G 是由参数化后的深度神经网络模型实现，其输入是一个从高斯分布中采样的随机向量 Z，输出可以看作采样于某个分布的一个样本 $X_{假}$。假设真实数据的分布为 P_{data}，在给定大量真实数据的前提下，对生成对抗网络进行训练，使得生成器 G 生成的数据分布接近于真实数据的分布，从而生成类似于真实数据的样本。在这个过程中，D 的输入是由真实样本和生成样本两部分组成，D 的作用是判别两个样本之间的差异。当 G 和 D 经过训练达到平衡状态，即 D 无法判断真实样本和生成样本之间的差异，此时可以认为生成器 G 拟合了真实数据的分布。输入一个从高斯分布采样的随机向量 Z，生成器便能重建出一张非织造布图像。

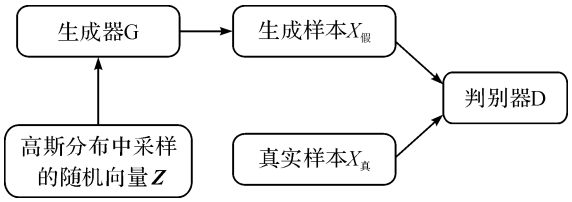

图 1　GAN 模型结构图

Fig. 1　GAN model structure diagram

1.2　模型结构

本文参考 GANs[12] 基本框架构建了生成模型 FGAN。为了生成器稳定重建出高质量的非织造布图像，判别器对网络最后 3 个特征层的输出进行监督，同时为了增加模型训练过程的稳定性，采用 PixelwiseNormalization 归一化层并引入标准化层。FGAN 结构如图 2 所示，模型使用一个全连接层对随机向量 Z 进行特征映射，然后将其调整成一个尺寸为 16×16×512 的三维矩阵（16×16 表示输入图像的分辨率，512 表示输入图像的维度）。

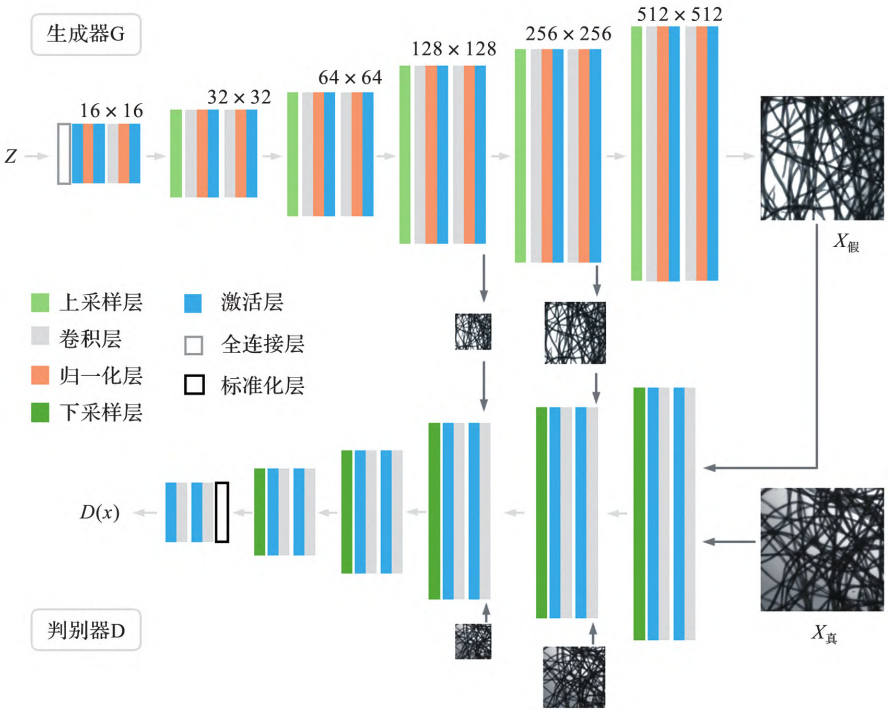

图 2　FGAN 模型结构图

Fig. 2　FGAN model structure diagram

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

生成器的网络结构一共有 6 层，每一层由 3 个基础模块组成，分别为卷积层、PixelwiseNormalization 归一化层和 LeakyReLU 激活函数。与传统 GANs 使用 BatchNormalization 归一化层不同的是，PixelwiseNormalization 归一化层没有需要训练的参数，其作用是将特征层中的每个像素在不同维度上的值归一化，PixelwiseNormalization 归一化层公式为：

$$b_{x,y} = \frac{a_{x,y}}{\sqrt{\frac{1}{C}\sum_{j=0}^{C} a_{x,y}^{j} + \epsilon}} \tag{1}$$

式中：$a_{x,y}$、$b_{x,y}$ 分别是输入和输出的特征层，ϵ 是防止除以零的常数。该模块能够防止像素位置上的信号在训练过程中失控，提升训练的稳定性。上采样层将分辨率尺寸扩大为原来的两倍，并且第 1 个卷积层将维度数减少为原来的一半，直到特征的空间尺寸达到 512 × 512，维度减少到 3，即红、绿、蓝 3 个通道。判别器的网络结构可以看作为生成器的镜像，如图 2 所示，判别器的输入分别是生成的假图和真实非织造布图像，输出的是一个概率值，用于表示输入数据是真实数据还是生成器生成的数据的概率。判别器的结构同样有 6 层，每层中间有一个下采样层使得图像的尺寸减半，第 1 个卷积层将维度数扩大一倍。判别器最后一层中引入标准化层，该层没有需要训练的参数，其作用是求取一个训练批次（Batch）内各个像素在维度上对应标准差，再求其均值，将其作为一个新维度与原来的特征层拼接。该维度反映了训练批次内像素在维度上的平均标准差，为模型提供了更丰富的特征表示，从而指导生成器生成更加多样化、更加接近真实数据分布的非织造布图像。

1.3 损失函数

FGAN 的损失由 3 部分组成：生成器损失、判别器损失和多样性损失。生成器损失的作用是让生成器生成逼真的非织造布图像，由内容损失和正则化项构成。内容损失用于衡量生成器生成的图像与真实图像之间的差异，使用均方误差（Mean squared error，MSE）来计算。正则化项的作用是防止生成器崩溃或产生不稳定的输出。生成器损失函数可以用式（2）表示：

$$L_G = \|x - G(z)\|^2 + \lambda \sum_{i=2}^{n} \left(\sqrt{E(\|\nabla_x D_{i-1}(x)\|_2 - 1)}\right)^2 \tag{2}$$

式中：x 表示真实图像，z 表示噪声向量，$G(z)$ 表示生成器的输出，$D_{i-1}(x)$ 是在第 $i-1$ 层判别器的输出，∇_x 是关于 x 的梯度，n 是总层数，E 表示期望。

本文判别器损失函数由两部分组成：Wasserstein 距离[13]和梯度惩罚项。Wasserstein 距离用来衡量两个分布之间的相似度，可以用来度量生成图像和真实图像之间的差异。梯度惩罚项可以防止在训练过程中出现梯度爆炸和梯度消失。判别器的损失 L_D 可以用式（3）表示：

$$L_D = E[D(x)] - E[D(G(z))] + \lambda_{GP} E[(\|\nabla_{\tilde{x}} D_{i-1}(\tilde{x})\|_2 - 1)^2] \tag{3}$$

式中：$\tilde{x}$ 是真实图像和生成图像的插值，$\nabla_{\tilde{x}}$ 是关于 $\tilde{x}$ 的梯度，λ_{GP} 是惩罚系数。

为了增加生成器生成样本的多样性，本文引入了权重多样性损失 WMI Loss。WMI Loss 运用于每个训练批次，在模型训练过程中，WMI Loss 计算生成数据分布与真实数据分布之间的 KL 散度均值。通过最小化 $L_{WMI}(G)$ 损失，可以使生成器生成更接近真实数据的样本，避免只生成单一纤维结构的非织造布图像。多样性损失 $L_{WMI}(G)$ 用式（4）表示：

$$L_{WMI}(G) = -\frac{1}{N}\sum_{i=1}^{N} K(Q(z \mid G(x_i)) \mid P(z)) \tag{4}$$

式中：G 是生成器，N 是样本数量，x_i 是输入样本，z 是隐空间向量，$P(z)$ 是隐空间的先验分布，$Q(z \mid G(x_i))$ 是在给定输入 x_i 的情况下生成器生成的 z 的分布，K 为 KL 散度，I 表示 KL 散度运算符。

综上，模型的总损失 L_{total} 可以表示为：

$$L_{total} = L_G + L_D + \lambda L_{WMI} \tag{5}$$

式中：λ 是超参数，用于控制多样性损失在总损失中的权重。通过多个批次的训练，计算目标函数的值，并通过反向传播机制来得到误差梯度，以利用梯度下降法来降低网络的训练误差，最终的目标是获得符合预期的高质量非织造布图像。

1.4 模型的多尺度训练

在传统 GANs 的训练中，通常采用一次性训练方式，即同时训练生成器和判别器的所有层。这种方式存在训练不稳定、生成图像质量差等问题[14-15]。为解决这一问题，本文在 ProGan[16]网络模型的渐进式训练基础上将模型的训练改进为多尺度训练策略，不同分辨率图像对应训练不同网络层。判别器不仅对最后生成图像进行监督，还对前两个网络层的输出特征进行监督。多尺度训

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

练策略有助于避免整体训练过程中出现梯度消失或梯度爆炸等问题,并且使生成器能够同时关注图像的细节和整体结构。通过在不同尺度上对生成图像进行监督,可以鼓励生成器生成更加逼真和细致的图像。

1.5　模型的评价指标

基于生成对抗网络重建的图像通常从以下两个方面进行评估: 一是图像的质量,生成的图像是否真实,是否清晰,结构是否完整; 二是多样性,在图像生成任务中,生成器所生成的图像应该具有多样性,如果生成单一纤维结构的无纺布图像,即出现模式坍塌的现象。一般使用 Inception score(*IS*) 和 Fréchet inception distance(*FID*) 两种常用指标对图像进行评估。*IS* 是基于 Inception 网络的分类器来计算图像的分类置信度和类别分布熵。然而,其网络分类在大规模图像分类任务(ImageNet) 上进行训练,在本文的非织造布数据集上的适用性受到限制。*FID* 能够适应不同数据集的特征分布差异,因此本文选取 *FID* 进行评价。*FID* 使用一个预训练的图像分类器网络作为特征提取器,该网络能够从图像中提取出高级语义特征,这些特征是分类器网络中某一层的输出。*FID* 的计算可用式(6) 表示:

$$FID = \|\mu_r - \mu_g\|^2 + T_r\left[\sum_r + \sum_g - 2\left(\sum_r \sum_g\right)^{1/2}\right] \quad (6)$$

式中: μ_r、μ_g 和 $\sum_r$、$\sum_g$ 分别表示生成和真实非织造布图像的特征均值与方差。真实图像与生成图像特征越接近,其均值与协方差就越小,则 *FID* 值也越小,生成图像的质量越高。

2　实验部分

2.1　数据集构建

为了获得高质量的非织造布图像,采用全自动光学显微镜对一块粘胶熔喷非织造布(面密度为 30 g/m^2,厚度为 0.153 mm) 样品拍摄获得纤维图像。显微镜平台为北昂医疗器械(上海) 有限公司生产的 M318 型全自动显微镜,主要包含摄像机、目镜、物镜、载物台、20 W 卤素光源与三轴电机等,如图 3 所示。拍摄获得大小为 1392 × 1040 个像素的 RGB 图像,同时在拍摄图像的过程中,移动不同视野获得不同纤维结构的图像,最终得到原始图像 1150 张。为了满足模型的训练要求,如图 4 所示对图像进行裁剪获得大小为 512 × 512 个像素的训练图像和验证图像 6975 张,其中: 5875 张用于模型训练,1000 张图像用于计算模型的评价指标,100 张图像用于验证模型性能。数据扩充是训练卷积神经网络常用的方法[17],能够有效防止模型过拟合,5875 张图像经过垂直、水平翻转扩充,获得 23000 张用于训练。

图 3　全自动光学显微镜

Fig. 3　Fully automatic optical microscope

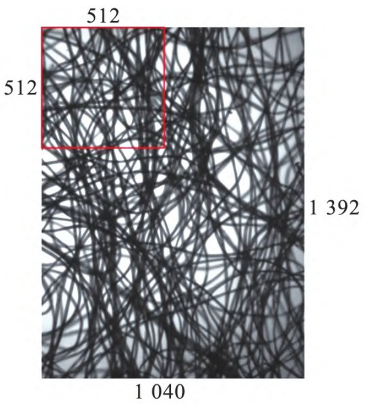

图 4　纤维显微图像的裁剪

Fig. 4　Cropping of the captured image

2.2　训练参数与环境配置

本文训练模型设置初始学习率为 0.0001,使用 Adam 优化器,动量参数为 0.0,学习率衰减率为 0.99。训练数据尺寸调整为 16 × 16、32 × 32、64 × 64、128 × 128、256 × 256、512 × 512,调整后的图像如图 5 所示,用于训练不同特征层,单个训练批次输入图像数量分别为 256、128、64、32、8、4。所有训练数据训练完一轮称为 1 个 epoch,不同特征层对应的训练 epoch 次数为 20、20、20、20、20、50 次。模型训练环境配置: 采用 Windows 10 的 64 位操作系统,使用深度学习框架 Pytorch1.13.1,CPU 为 3.60 GiHz Intel(R) Core(TM) i7-12700KF,GPU 为 NVIDIA GeForce RTX 3080 Ti。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

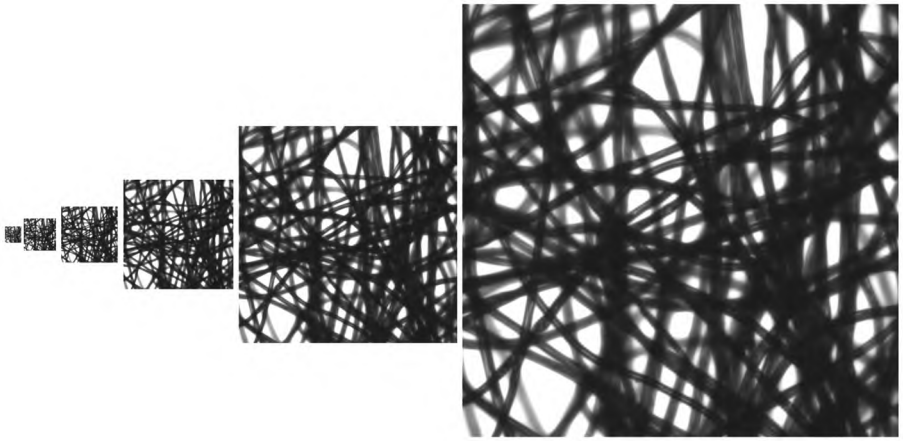

图 5 不同分辨率下的纤维显微图像

Fig. 5 Fiber microscopic images at different resolutions

2.3 生成效果展示

通过使用大量真实的非织造布图像对模型进行逐步增强训练和整体训练，总训练耗时 68.5 h。最终模型学习到非织造布的纤维结构分布，输入一个从高斯分布中采样的随机向量便能够生成一张真实的非织造布图像。在整体训练阶段每隔 5 个 epoch 便对模型进行一次验证并保留该批次的模型参数文件。验证示例图像如图 7 所示。从图 6 中可以看出，在训练初期模型能够学习到整体的纤维结构分布，但在细节上不够完美，有较多的纤维并不连续，并且纤维结构不够真实。随着训练批次的增加，模型对整体纤维结构不断优化，纤维的形态和连续性越来越自然，最终生成图在纤维形态上与真实图几乎一致。

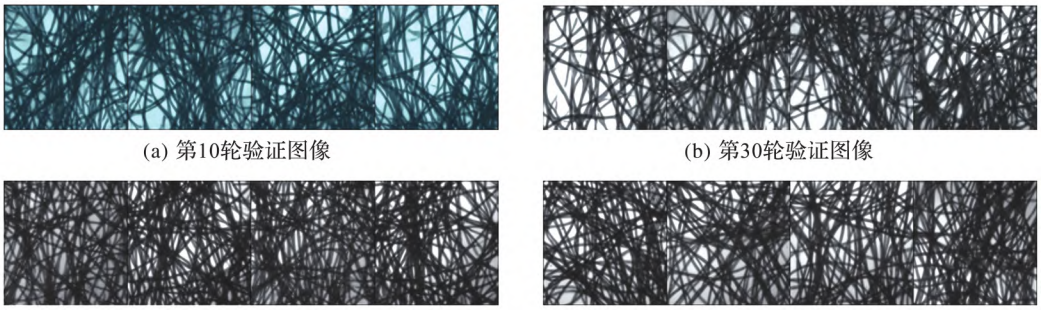

(a) 第10轮验证图像 (b) 第30轮验证图像

(c) 第50轮验证图像 (d) 真实图像

图 6 不同训练批次下的生成图像和真实图像

Fig. 6 Generated and real images of different training batches

2.4 对比实验

为验证本文所提出模型 FGAN 的性能，进行了一系列的对比实验。实验结果如图 7 所示，分别是 DCGAN[18]、WGAN-GP[19]、BEGAN[20]、PROGAN[16]、FGAN 的生成图像结果和真实图像。从图 7 可以看出，DCGAN 在本文非织造布图像重建中存在图像模糊、纤维结构不清晰的问题。WGAN-GP 和 BEGAN 重建的图像中纤维结构不真实，图像有明显失真。基于噪声生成高质量图像的方法 PROGAN，从视觉效果上生成了较真实的非织造布图像，但生成的图像的质量与真实图像仍有差距，纤维的颜色和结构与真实图像有明显差异。与上述方法相比，本文提出的 FGAN 可以生成结构多样化的非织造布图像，并且在视觉上几乎和真实图像一致；同时 FGAN 产生的图像并未出现失真问题。这主要是由于模型采用逐层训练的方式，在训练阶段学习到更好的数据分布；此外，引入的 WMI Loss 也有助于提升模型的性能。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

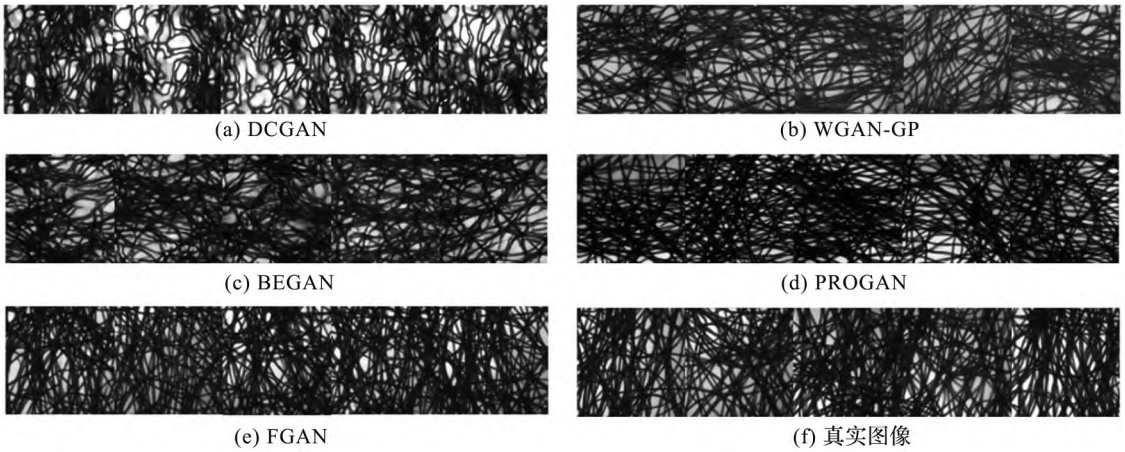

图 7　不同模型的生成图像与真实图像

Fig. 7　Generated and real images of different models

本文使用 *FID* 定量评估模型，结果如表 1 所示。从表 1 可见，模型所生成的图像的 *FID* 值为 25.51，相较于 PROGAN 降低了 35.77%，且远低于 DCGAN、WGAN-GP、BEGAN。相比之下，本文提出的模型能生成更高质量，纤维结构更真实的非织造布图像。

表 1　FGAN 与其他生成模型的对比

Tab. 1　Comparison between FGAN and other generative models

模型	*FID*
DCGAN	141.52
WGAN-GP	145.85
BEGAN	814.44
PROGAN	40.35
FGAN	25.51

2.5　消融实验

为了进一步验证 WMI Loss 和多尺度训练策略的有效性，本文 FGAN 进行了消融实验，实验结果如表 2 所示。使用传统训练策略训练模型，得到模型生成图像的评估指标 *FID* 值为 40.21，添加 WMI Loss 后模型生成图像的 *FID* 值降低了 20.31%，表明 WMI Loss 有助于生成器学习更多的纤维结构信息。此外，采用多尺度训练策略与传统一次性训练所有层相比 *FID* 降低了 24.52%，表明该方法同样能够提高模型的性能。WMI Loss 与多尺度训练结合进一步增强了模型的生成能力，从而生成了纤维排列更真实的非织造布图像。

2.6　验证实验

分析非织造布孔隙结构的方法分为: 实验法和图像法。实验法测量孔隙率的方法有多种，包括液体渗透法、气体渗透法、压汞法等。液体渗透法和气体渗透法是通过测量渗透液体或气体的体积来计算孔隙体积，相对简单易行，但在处理一些特殊非织造布时可能存在一定的局限性。压汞法可以直接测量孔隙体积，但在实验过程中需要使用昂贵的压力计和有毒的汞，不太适合大规模应用。

表 2　不同方法的消融实验结果

Tab. 2　Results of ablation experimentsby different methods

传统训练策略	WMI Loss	多尺度训练	*FID*
√			40.21
	√		32.04
		√	30.35
	√	√	25.51

注: √表示模型训练选择该方法。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

相对于实验法，图像分析法有着明显的优势。首先，图像法不需要接触样品，避免了样品损伤和污染，能够更好地保护样品的完整性。其次，图像法能够观察孔隙形态和大小，提供更为详细、准确的孔隙信息，这对于研究非织造布的物理性质和结构特征有重要意义。相关研究[21]对比了实验法和图像法测量织物的孔隙率，结果表明实验法在测试过程中受多种因素的干扰而影响最终的结果。因此为了验证本文模型生成非织造布图像的真实性，采用图像法分析验证真实图像与生成图像的平均孔隙率以及孔隙分布，分析过程如图 8 所示。

(a) 纤维图像　(b) 二值化　(c) 计算孔隙率和统计孔隙大小

图 8　图像法分析过程

Fig. 8　Image analysis process

采取孔隙率和孔隙分布两个指标对非织造布图像的结构进行量化分析，生成图像和真实图像经过二值化处理后，计算图中白色像素占总像素的比值即为孔隙率。孔隙率 ϕ 用式(7)表示:

$$\phi/\% = 100 \times \frac{A_p}{A_t} \tag{7}$$

式中: ϕ 表示孔隙率，A_p 表示孔隙面积，A_t 表示总面积。

使用 OpenCV 图像处理库函数获取图像中的连通区域，每一个连通区域代表一个孔隙，计算出每个连通区域内的像素个数，以该数值作为孔隙的大小。使用训练好的模型重建出 100 张非织造布图像与 100 张未参与模型训练的验证图像，经过如图 8 所示的处理过程后计算得到每张图像的平均孔隙率，结果如图 9 所示。从图 9 中可以看出，模型生成图像的平均孔隙率(30.02%)与真实非织造布的平均孔隙率(30.87%)十分接近。

统计出生成图像与真实图像中孔隙的数量，结果如图 10 所示，得到生成图像与真实图像的孔隙数量分布曲线重合度较高，在不同的区间内有着数量接近的孔隙，模型生成的非织造布图像孔隙分布与真实图像一致。

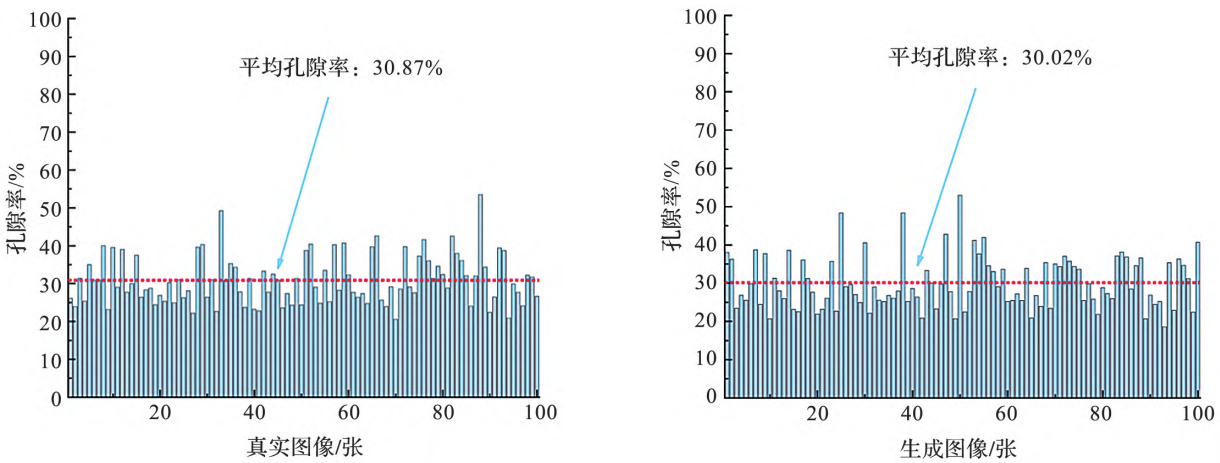

图 9　生成图与真实图孔隙率

Fig. 9　Porosity of generated and real images

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

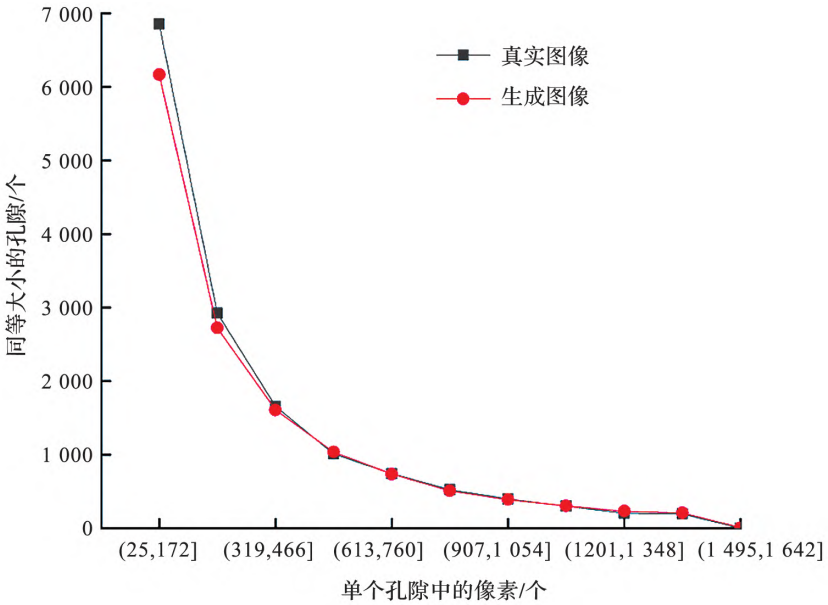

图 10　生成图与真实图孔隙分布

Fig. 10　Pore distribution in generated and real images

3　结　语

本文提出了一种基于生成对抗网络的非织造布图像重建新方法。构建了纤维生成对抗网络模型 FGAN，通过真实的非织造布图像数据集进行训练学习，实现了对高分辨率非织造布图像的重建。为了验证重建图像的纤维结构排列与真实图像的一致性，选取了孔隙率和孔隙数量分布两个指标，对 100 张真实图像与生成图像进行了对比分析。结果显示，FGAN 重建的图像与真实图像在纤维形态与结构分布上接近一致，且生成图像的质量优于其他模型，验证了本文方法的可行性。基于体视学理论，通过堆叠二维图像能够对非织造布的真实三维结构数据进行建模和仿真，本文研究成果可为非织造布立体结构分析研究提供技术支撑。

参考文献:

[1] HAJIMOHAMMADI M, SOLTANI P, SEMNANI D, et al. Nonwoven fabric coated with core-shell and hollow nanofiber membranes for efficient sound absorption in buildings [J]. Building and Environment, 2022, 213: 108887.

[2] 金关秀，祝成炎. 孔隙形状对熔喷非织造布过滤品质的影响 [J]. 上海纺织科技，2018，46(11)：15-18.
JIN Guanxiu, ZHU Chengyan. Effect of pore shape on the filter quality of melt-blown nonwoven [J]. Shanghai Textile Science & Technology, 2018, 46(11): 15-18.

[3] 田伟，雷新，从明芳，等. 纺粘非织造布制备工艺与性能的关系 [J]. 纺织学报，2015，36(11)：68-71.
TIAN Wei, LEI Xin, CONG Mingfang, et al. Relationship between manufacture process and performance for spunbond nonwoven [J]. Journal of Textile Research, 2015, 36(11): 68-71.

[4] 潘莺，王善元. 模拟熔喷纤网的孔径分布及其对过滤性能的影响 [J]. 中国纺织大学学报，2000，26(5)：73-77.
PAN Ying, Wang Shanyuan. Simulation of melt blown web and the effect of its poresize distribution on filtration performance [J]. Journal of China Textile University, 2000, 26(5): 73-77.

[5] SIMMONDS G E, BOMBERGER J D, BRYNER M A. Designing nonwovens to meetpore size specifications [J]. Journal of Engineered Fibers and Fabrics, 2007, 2(1): 155892500700200.

[6] 金关秀，祝成炎. 基于图像模拟和支持向量机的复合非织造布孔隙尺寸预测 [J]. 纺织学报，2022，43(12)：75-81.
JIN Guanxiu, ZHU Chengyan. Prediction of pore dimension in composite nonwovens based on image simulation and support vector machine [J]. Journal of Textile Research, 2022, 43(12): 75-81.

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[7] 杨旭红. 非织造材料(纤维网)形态结构的表征与分形模拟[D]. 苏州: 苏州大学,2003: 27-30.
YANG Xuhong. Expression and Fractal Simulation of Morphologic Structures of Nonwovens [D]. Suzhou: Soochow University, 2003: 27-30.

[8] 高贵. 利用分形理论研究非织造布的结构及透通性[D]. 天津: 天津工业大学,2005: 38-45.
GAO Gui. UsingFractal Theory to Study the Structure and Permeability of Nonwoven Fabrics [D]. Tianjin: Tiangong University, 2005: 38-45.

[9] WANG J, SHI Q, AKANKWASA N T, et al. Establishment of the three-dimensional model of the nonwoven structure with fiber scale based on the GAN algorithm [J]. Textile Research Journal, 2022, 92(9/10): 1656-1665.

[10] AYDILEK A H, OGUZ S H, EDIL T B. Constriction size of geotextile filters [J]. Journal of Geotechnical and Geoenvironmental Engineering, 2005, 131(1): 28-38.

[11] CRESWELL A, WHITE T, DUMOULIN V, et al. Generative adversarial networks: An overview [J]. IEEE Signal Processing Magazine, 2018, 35(1): 53-65.

[12] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial networks [J]. Communications of the ACM, 2020, 63(11): 139-144.

[13] LIU H, GU X, SAMARAS D. Wasserstein GAN with quadratic transport cost [C] // International Conference on Computer Vision (ICCV). Seoul, Korea (South). IEEE, 2020: 4831-4840.

[14] ZHUJ Y, PARK T, ISOLA P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks [C] // International Conference on Computer Vision (ICCV). Venice, Italy. IEEE, 2017: 2242-2251.

[15] ZHANG H, GOODFELLOW I, METAXAS D, et al. Self-attention generative adversarial networks [EB/OL]. 2018. https://arxiv.org/abs/1805.08318.

[16] KARRAS T, AILA T, LAINE S, et al. Progressive growing of GANs for improved quality, stability, and variation [EB/OL]. 2017. https://arxiv.org/abs/1710.10196.

[17] SHORTEN C, KHOSHGOFTAAR T M. A survey on image data augmentation for deep learning [J]. Journal of Big Data, 2019, 6(1): 1-48.

[18] RADFORD A, METZ L, CHINTALA S. Unsupervised representation learning with deep convolutional generative adversarial networks [EB/OL]. 2015. https://arxiv.org/abs/1511.06434.

[19] GULRAJANI I, AHMED F, ARJOVSKY M, et al. Improved training of wasserstein gans [C] // Proceedings of the 31st International Conference on Neural Information Processing Systems, 2017: 5769-5779.

[20] BERTHELOT D, SCHUMM T, METZ L. Began: Boundary equilibrium generative adversarial networks [EB/OL]. 2015. https://arxiv.org/abs/1511.06434.

[21] 张潇,贺晓亚. 计算机图像技术在织物性能测试分析中的应用[J]. 国际纺织导报,2022,50(4): 32-35.
ZHANG Xiao, HE Xiaoya. Application of computer image technology in fabric properties testing and analysis [J]. Melliand China, 2022, 50(4): 32-35.

国之栋梁不可无,生命之水不可枯

——公益广告

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

2D Image reconstruction of nonwoven fabrics based on generative adversarial networks

WANG Zhilu[1a], *HOU Jue*[1a,1b,2], *YANG Yang*[1a,1b], *LIU Zheng*[1b,1c]

(1a. School of Fashion Design & Engineering; 1b. Zhejiang Provincial Research Center of Clothing Engineering Technology; 1c. International Institute of Fashion Technology, Zhejiang Sci-Tech University, Hangzhou 310018, China; 2. Wuhan Textile and Apparel Digital Engineering Technology Research Center, Wuhan Textile University, Wuhan 430073, China)

Abstract: Nonwovens are widely used as various filter materials, gas or particle adsorption materials, sound insulation materials, etc. in such fields as medical and health care, tourism, construction and waterproofing, and agriculture. The functions of nonwovens are closely related to the structure of their fiber collections. On the premise that nonwovens are randomly arranged in the layers of the fiber network, researchers usually use parametric simulation, fractal theory or image generation algorithms to simulate the fibers of nonwovens. However, the fiber structure generated in this way has the following problems: a) the fiber morphology based on parametric simulation is linear and does not agree with the actual fiber curl state; b) the fractal theory-based simulations cannot reconstruct the real nonwoven fabric structure concretely; c) the single fiber morphology reconstructed based on the generation algorithm is different from the real state of the fiber morphology.

Toreconstruct a realistic image of the nonwoven fiber structure, this paper constructs a generative adversarial network (FGAN) with a multiscale training strategy on the GAN base framework. To improve the stability of model training, a multi-scale training strategy is used to train the model, and PixelwiseNormalization layer and standardization layer are also introduced in the construction of the model. The reconstructed fiber structure is randomly arranged, which is consistent with the real nonwoven fiber arrangement. To increase the diversity of fiber structures in the generated images, a weight diversity loss WMI Loss is proposed. the model is trained for a long time, and the final generator is stable to generate nonwoven images that are consistent with the real images. Compared with other generative models, FGAN has better stability and the reconstructed nonwoven images have higher quality and more diverse fiber structures. Also, to verify the effectiveness of multiple-degree training strategy and weight diversity loss, ablation experiments are performed on the model. The experimental results show that the evaluation index *FID* of the model-generated images is reduced by 24.52% under the effect of the multiscale training strategy and by 20.31% under the effect of the weight diversity loss. Finally, in order to verify the structural consistency between the generated images and the real images, the average porosity of the real images is calculated to be 30.87% and the average porosity of the generated images is 30.02%, which are very close to each other. And the pore number distribution curves of the generated image and the real image have a high overlap. From the above analysis, it can be verified that the porosity and pore distribution of the nonwoven fabric images generated by the model are consistent with the real images.

FGAN can reconstruct high quality 2D images of nonwovens, from which detailed information on fiber distribution and morphology can be obtained. This information can be used for nonwoven performance analysis, optimization of production processes, etc. The method is able to reconstruct a diverse range of thin nonwoven structures, while the analysis of thicker nonwoven structures is yet to be investigated.

Keywords: Nonwoven fabric; pore; generate adversarial networks; diversity loss; image generation

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net