DOI:10.13475/j.fzxb.20230904501

基于混合知识蒸馏和特征增强技术的轻量级无解析式虚拟试衣网络

侯　珏[1,2], 丁　焕[1], 杨　阳[1,2], 陆寅雯[1], 余灵婕[3], 刘　正[2,4]

(1. 浙江理工大学 服装学院, 浙江 杭州　310018; 2. 丝绸文化传承与产品设计数字化技术文旅部重点实验室, 浙江 杭州　310018; 3. 西安工程大学 纺织科学与工程学院, 陕西 西安　710018; 4. 浙江理工大学 国际时装技术学院, 浙江 杭州　310018)

摘　要　基于外观流的二维虚拟试衣技术存在着服装扭曲准确率低、纹理失真以及模型计算成本高等问题,提出了一种基于混合知识蒸馏和特征增强的轻量级无解析式虚拟试衣模型。首先,通过全局特征的融合与不同尺度下流场运算结果的校准,提出了改进后的外观流估计方法,提高外观流的估计精度;其次,采用知识蒸馏的方法对图像分割结果与虚拟试衣流程进行解耦,构建了基于深度可分离卷积的轻量级试衣网络;最后,提出了基于像素平均梯度的服装复杂度 GTC 指标量化分析服装的纹理复杂程度,以此为基础将 VITON 数据集划分为简易纹理集、较复杂纹理集和复杂纹理集。结果表明:提出的模型在图像质量评价指标(弗雷歇距离、感知图像块相似度、峰值信噪比、内核初始距离)上的分值较目前性能最优的模型均有所提升,能够有效提高服装扭曲准确度与试穿结果图像的质量,缓解服装纹理畸变与失真的问题,同时还拥有更小的模型尺寸和更快的运行推理速度。

关键词　虚拟试衣; 外观流; 知识蒸馏; 特征增强技术; 服装复杂度; 服装电子商务

中图分类号:TS 942.8　　**文献标志码**:A

如今,线上购物已成为消费者购买服装的重要渠道,然而网购平台难以为其提供全面的个性化风格搭配方案,导致实际着装效果难以达到消费者的预期,进而引发网购模式下服装商品高退换货率的现象,因此,利用二维虚拟试衣技术解决线上试衣问题,对提升消费者的购物体验、推动服装电子商务的发展具有重要意义。早期的虚拟试衣技术[1-3]主要基于三维测量与三维模型的方法来实现,但该种方法需要大量的计算资源,难以适应移动互联网的使用场景。对此,目前研究者们采用深度学习的方法对基于二维图像的虚拟试衣任务展开进一步研究。

二维虚拟试衣通常分为服装扭曲、着装人物合成 2 个阶段。其中,服装扭曲采用薄板样条插值法[4](thin-plate spline, TPS)或外观流估计法,将目标服装图像扭曲至相应人体姿态下的形状分布;着装人物图像的合成则利用生成对抗网络[5](generative adversarial network, GAN)中的生成器部分,将扭曲后的目标服装图像与待试穿者图像融合生成着装人物图像。如 Han 等[6]借助 VITON 利用人体解析信息[7-8],提取与目标服装图像之间的相关性,通过薄板样条插值对目标服装进行扭曲。Han 等[9]提出 ClothFlow,通过外观流估计法对人体解析信息与目标服装进行密集匹配,解决复杂人体位姿情况下薄板样条插值法的失灵现象。

尽管以上研究通过引入不同的服装扭曲方法提升了试衣精度,但仍存在一些问题:首先,带有复杂纹理的服装会因扭曲过程中的巨大形变而导致其细节部位产生畸变和失真;其次,二维虚拟试衣十分依赖人体解析信息的准确度,当人体解析信息出现较大错误时,试衣结果仍会保留这些错误;此外,移动互联网要求模型轻量化以实现部署,但先前的虚拟试衣模型计算复杂度高、模型尺寸大,无法满足模型实际的硬件部署需求。

针对上述问题,本文提出了一种基于知识蒸馏和特征增强技术的轻量级无解析式虚拟试衣模型,通过不同尺度下特征信息的融合增强、各外观流场的校准、混合蒸馏机制的引入,在减少模型条件输入的同时,实现了更高精度外观流场的估计,改善了服装纹

收稿日期:2023-09-18　　**修回日期**:2024-03-23

基金项目:国家自然科学基金项目(62201441);武汉纺织服装数字化工程技术研究中心开放基金项目(SZH202201);浙江省科技计划项目(2023C03181);嘉兴市重点研究计划项目(2023BZ10009)

第一作者:侯珏(1990—),男,讲师。主要研究方向为纺织图像处理、深度学习。

通信作者:刘正(1981—),男,教授,博士。主要研究方向为数字化服装技术。E-mail:koala@zstu.edu.cn。

中国知网　https://www.cnki.net

理畸变的现象,并提高了模型的运行速度。最后,提出一种用于衡量服装纹理复杂程度的评价指标——服装复杂度,对 VITON 数据集进行样本划分,为二维虚拟试衣模型提供更广泛的性能量化选择。

1　虚拟试衣研究现状

1.1　基于外观流估计法的虚拟试衣

外观流是用于表示图像像素级变形的二维坐标向量。外观流估计法被广泛应用于姿态迁移、视频帧预测等任务,并最先由 ClothFlow 在二维虚拟试衣任务中引入。Han 等[9]在 ClothFlow 中提出以人体姿势为引导的双通道级联外观流估计网络,以最低尺度特征为基准逐级进行外观流细化与图像特征扭曲,并额外引入人体语义分割阶段,用于指导更高精度试衣图像的生成。Chopra 等[10]在 ZFlow 中引入针对多尺度外观流估计的门控机制,防止过度扭曲导致的服装畸变与失真现象,并将最终输出的人体着装结果与网络输入的人体解析信息进行密集对应,以保证皮肤、领口等部位的完整性。

Lee 等[11]在 HR-VITON 中将服装扭曲与人体解析信息校准集合在一个模块,并引入针对人体解析信息校准的判别器提升其校准性能,以此减少因错误先验信息导致的服装扭曲精度低的问题。Xie 等[12]在 GP-VTON 中提出本地流全局解析扭曲模块,针对不同服装部位进行局部外观流估计,并对各局部外观流进行基于全局信息的融合,以解决复杂试穿姿势下服装扭曲失灵问题。Bai 等[13]在所提出的 SDAFN 中将可变形注意力机制与外观流估计法相结合,从而推断自注意力外观流和交叉注意力外观流并进行相应的信息交互与融合,从而提高服装的扭曲配准精度。

外观流估计法作为使用最广泛的服装扭曲方法之一,在面临复杂试穿姿势时,其服装扭曲精度和稳定性均优于传统的扭曲方法,但是,在某些特定情况下,例如出现手部关节遮挡躯干,以及试穿服装具有复杂的花纹与图案时,该方法难以实现精准的像素对齐和轮廓配准,导致服装纹理畸变现象的出现。

1.2　基于知识蒸馏的虚拟试衣

知识蒸馏作为最常见的模型压缩方法,通常由 2 个独立网络构成,即由预先训练的、模型尺寸较大的教师网络,以及经教师网络指导训练、模型尺寸较小的学生网络组成。Ge 等[14]提出的 PF-AFN 采用知识蒸馏的方法流程将经预训练的基于人体解析图像的虚拟试衣模型作为教师网络,使用其试衣结果作为学生网络的条件输入构成循环,对学生网络进行知识迁移和训练,不仅可以减少学生网络的条件输入,还可以克服试衣模型对人体解析信息的高敏感度问题。此外,该网络利用目标服装图像与人体解析信息之间的相关性进行密集匹配,并获得以矢量表示的相关性图,更有效地捕捉服装图像与着装人物图像之间的长程对应关系。在 PF-AFN 的基础上,He 等[15]在 Style-VTON 中引入基于 StyleGAN[16]的全局风格向量作为外观流推断的依据之一,加强全局信息对服装扭曲过程的监督,还引入多尺度外观流细化模块以保持局部服装的变形精度,极大程度上改善复杂位姿情况下服装扭曲准确度低的问题。

基于知识蒸馏以及无人体解析图像的虚拟试衣通过减少试衣模型的输入,降低了二维虚拟试衣的实际使用门槛,有效改善了基于人体解析信息方法中模型输入繁琐的问题,但是,该方法在教师网络的指导监督下,并未完全解耦教师网络中所使用的人体解析信息,导致其继承了教师网络对人体解析信息敏感的问题。

本文所提出的虚拟试衣网络延续了基于知识蒸馏的虚拟试衣工作,通过引入更加准确高效的服装扭曲匹配模块和自蒸馏机制对服装扭曲阶段进行更加有效的研究和调整。

2　本文模型

基于二维图像的虚拟试衣是将所给定的目标服装图像换装至待试衣人体图像的对应部位,并保持相应人体姿势和其它人体部位细节不变。

为将人体解析图像与最终试衣结果进行解耦,消除错误人体解析信息对最终试衣结果的精度影响,本文使用循环蒸馏结构作为主要的模型架构,实现无解析人体图像作为模型条件输入的最终目的。该结构可以分为 2 个部分:1)经过预训练的基于人体解析图像的教师试衣网络;2)基于无人体解析图像的学生试衣网络。并且,该教师-学生网络均由服装扭曲匹配模块 WN 和试衣模块 GN 组成,其网络主干如图 1 所示。

2.1　教师-学生网络训练流程

首先,本文使用配对目标服装图像和待试衣人体图像训练教师试衣网络。其中,待试衣人体图像被预处理为 1 个具有丰富人体解析信息的人体解析图像组,包括人体密集位姿分割图像[17]、人体姿态解析图像和包含手掌、头发、脸、下装的人体掩码图像,并将以上信息作为教师试衣网络的条件输入。通过匹配相关人体解析信息,服装扭曲匹配教师网络 WN-T 将推断对应外观流场,并利用外观流场对

中国知网　https://www.cnki.net

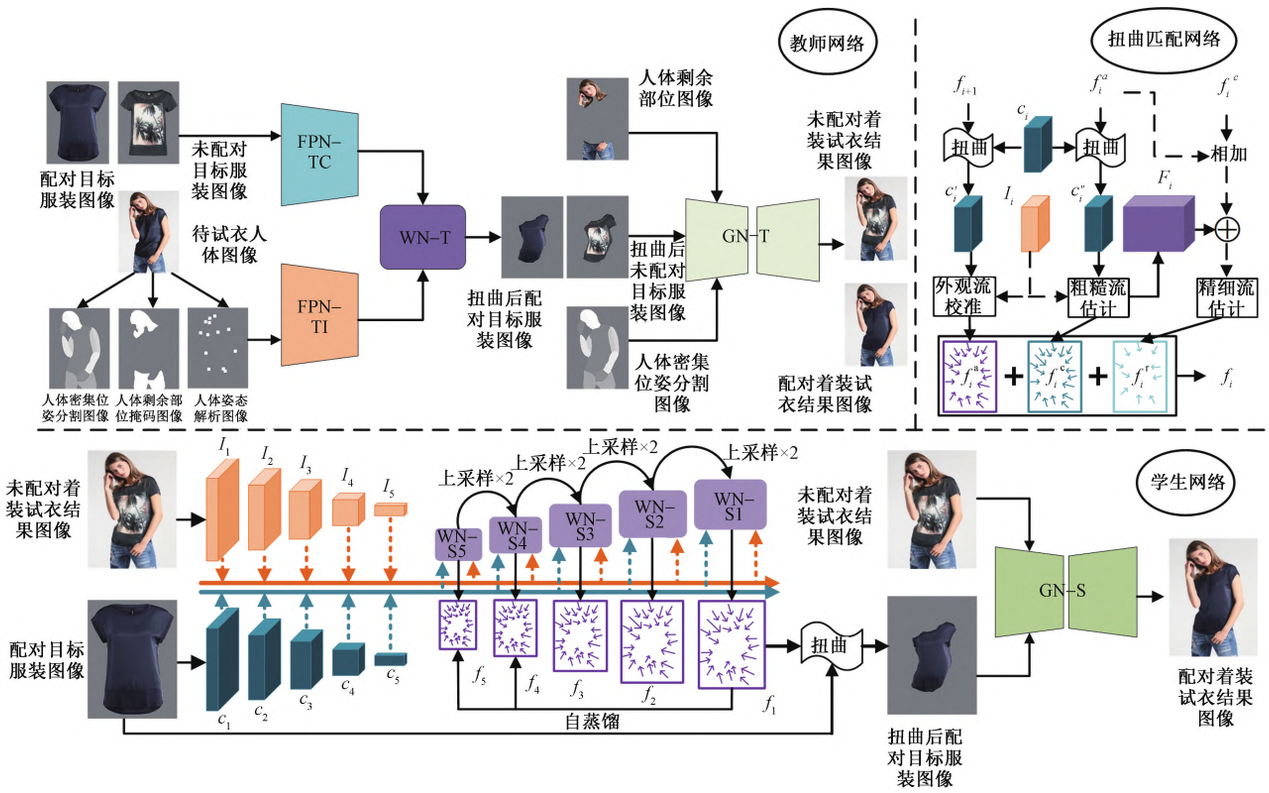

注:图中人物图像均来源于 VITON 数据集,仅作效果展示。

图 1　网络主干图

Fig. 1　Network backbone

配对目标服装图像进行扭曲并获得扭曲后配对目标服装图像。在此基础上,将其和人体其它部位图像输入教师试衣生成器 GN-T,并在人体密集位姿分割图像的指导下获得配对着装试衣结果图像。

教师网络训练完成后,随机选择未配对的目标服装图像和经预处理的人体解析图像组作为教师网络的输入,获得未配对着装试衣结果图像,令其作为学生网络的条件输入,最终预测配对着装试衣结果图像,以实现学生网络训练。

2.2　服装扭曲匹配网络

2.2.1　特征提取器

服装扭曲匹配教师网络 WN-T 与服装扭曲匹配学生网络 WN-S 具有相同层数的金字塔特征提取器结构[18](feature pyramid networks, FPN),该特征提取器分别有 2 个特征提取通道,且拥有相同的卷积结构提取不同尺度的特征图像 c_i、I_i,其中 $i \in \{1,2,3,\cdots,5\}$。所提取的特征图像将作为匹配信息送入对应尺度的服装扭曲匹配子网络,推断获得相应的外观流场 f_i。值得注意的是,为更好地裁剪和过滤冗余的参数,服装扭曲匹配学生网络 WN-S 所提取对应层级的特征图像通道数是服装扭曲匹配教师网络 WN-T 的二分之一,大幅降低了模型尺寸,提高了模型的预测速度。

此外,由于教师-学生特征提取器所提取对应层级的特征图尺度不同,为使二者之间能够进行基于特征的蒸馏,本文在服装扭曲匹配学生网络 WN-S 上运用 1×1 卷积层,允许教师和学生之间不同维度的输出特征映射。

2.2.2　外观流场估计

基于外观流的虚拟试衣利用人体解析信息推断相应偏移量,以实现服装扭曲目的。首先,本文利用跨尺度的特征信息增加上下文信息之间的交互,对上采样后的外观流场进行针对当局特征的校准,减少上采样所导致的信息丢失现象,例如目标服装边界模糊和不流畅问题。随后本文使用经校准的外观流结合当前尺度的特征信息预估粗糙流场,并对当前尺度的特征信息进行信息增强获得全局信息融合特征块,最后利用增强后的融合特征块预估精细流场,减少目标服装扭曲过程中出现的纹理畸变、失真现象。

具体来说,本文首先通过该匹配网络对来自上一尺度的外观流进行校准,并作为该尺度下的外观流调制基准:

$$f_i^{\mathrm{u}} = \begin{cases} U(f_{i+1}), & i \in \{1,2,\cdots,4\} \\ \mathrm{Conv}_{\mathrm{b}}(c_i, I_i), & i = 5 \end{cases}$$

$$c_i' = W(c_i, f_i^{\mathrm{u}})$$

$$f_i^{\mathrm{a}} = W_f(f_i^{\mathrm{u}}, \mathrm{Conv}_1(c_i', I_i))$$

中国知网　https://www.cnki.net

式中:f_{i+1} 代表来自上一尺度的外观流;U 代表上采样操作;$\mathrm{Conv_b}$ 代表普通卷积操作;f_i^{u} 代表上采样后的外观流。当 $i=5$ 时,扭曲匹配网络的初始子网络无法获得来自上一尺度的外观流,因此本文对服装、条件特征图 c_i、I_i 进行普通卷积操作,并将该操作获得的外观流视为上采样后的外观流。c_i'代表经上采样外观流 f_i^u 扭曲后的服装特征图;W 代表针对特征图的扭曲操作;$\mathrm{Conv_1}$ 代表校准卷积操作;W_{f} 代表针对外观流的扭曲操作;f_i^{a} 代表校准后的外观流。为尽可能提取全局特征所包含的匹配信息,本文利用校准后的外观流推断粗糙外观流 f_i^{c},并在此阶段通过特征增强技术对条件特征信息和服装特征信息进行多次融合,获得特征增强后的融合特征块 F_i:

$$c_i''=W(c_i,f_i^{\mathrm{a}})$$

$$f_i^{\mathrm{c}}=\mathrm{Conv_2}(c_i'',I_i)$$

$$F_i=\mathrm{Conv_e}(c''_i,I_i)$$

式中:c_i''代表经校准后外观流 f_i^{a} 扭曲的第 i 层服装特征图;$\mathrm{Conv_2}$ 代表粗糙估计卷积操作;$\mathrm{Conv_e}$ 代表特征增强操作,即通过多次残差连接加卷积的方式增强特征之间的信息匹配能力,其粗糙外观流估计网络结构图如图 2 所示。特征增强后的融合特征块 F_i 具有更加广阔的全局视野,本文将其作为推断精细外观流 f_i^{r} 的主要依据,减少以往方法所出现的低频信息丢失现象:

$$f_i^{\mathrm{r}}=\mathrm{Conv_3}(F_i,f_i^{\mathrm{a}}+f_i^{\mathrm{c}})$$

式中:$\mathrm{Conv_3}$ 代表细化卷积操作。最后对校准后外观流 f_i^{a}、粗糙外观流 f_i^{c} 和精细外观流 f_i^{r} 进行相加,获得该尺度下的最终外观流 f_i:

$$f_i=f_i^{\mathrm{a}}+f_i^{\mathrm{c}}+f_i^{\mathrm{r}}$$

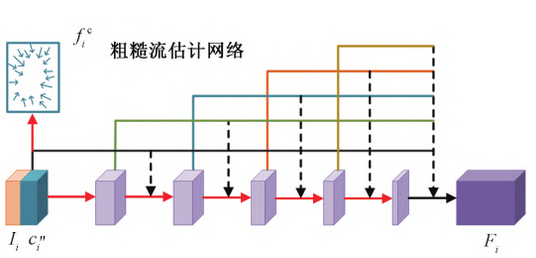

图 2　粗糙流估计网络结构图

Fig. 2　Backbone of coarse flow estimator

2.3　试衣生成器

试衣生成器的主要作用是将扭曲后的目标服装与未着装人物进行图像融合,生成一张逼真的试穿图像。在训练学生试衣生成器 GN-S 时,教师试衣生成器 GN-T 将人体密集姿态图像、人体其它部分图像(包括头发、脸部、手掌、下装)、扭曲后的未配对着装试衣结果图像作为输入,而学生试衣生成器 GN-S 是将教师网络输出的未配对着装试衣结果图像、扭曲后目标服装图像作为输入。教师、学生网络的试衣生成器均采用 Res-Unet 结构,即结合 Unet[19] 与残差网络[20](Resnet)获得逼真的试衣图像。为压缩模型整体尺寸,本文在学生试衣生成器 GN-S 的基础残差网络中运用深度可分离卷积[21-22],在保证低精度损失的前提下可大幅减少模型参数量,加速模型的训练和测试,其基础残差结构图如图 3 所示。

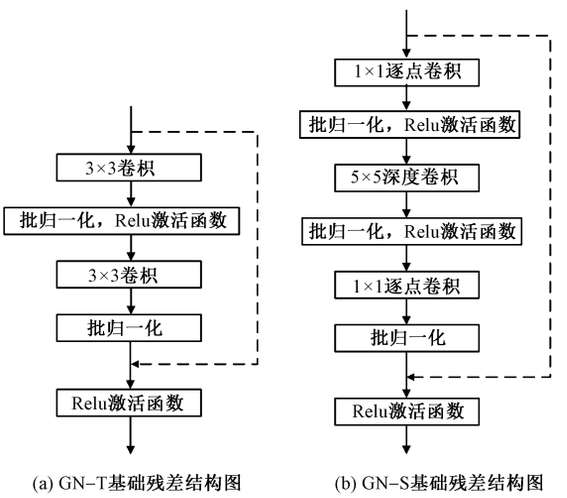

图 3　各模型基础残差结构图

Fig. 3　Basic Res-Net structure of each model. (a) Basic Res-Net structure of GN-T; (b) Basic Res-Net structure of GN-S

2.4　损失函数

2.4.1　服装扭曲及着装生成损失函数

为训练本文的试衣生成模型并获得高视觉保真度,本文首先对试衣生成器生成的试衣结果图像和真实的人体图像使用感知损失[23],公式为

$$L_{\mathrm{VGG}}^{\mathrm{G}}=\sum_i \| \varnothing_i(I_c)-\varnothing_i(\hat{I}_c) \|$$

式中:$L_{\mathrm{VGG}}^{\mathrm{G}}$ 代表图像感知损失;$\varnothing_i$ 代表预训练的 VGG 网络[24]中的第 i 层;$\hat{I}_c$ 代表学生试衣网络所输出的配对着装试衣结果图像;I_c 代表待试衣人体图像。

其次,为训练服装扭曲匹配网络,本文对扭曲后的服装图像应用了 1 个绝对值损失:

$$L_{\mathrm{L1}}^{\mathrm{w}}=\| c^{\mathrm{w}}-m_{\mathrm{c}}I_{\mathrm{c}} \|+\| c_{\mathrm{mask}}^{\mathrm{w}}-m_{\mathrm{c}} \|$$

式中:$L_{\mathrm{L1}}^{\mathrm{w}}$ 代表针对扭曲后服装及其掩码的绝对值损失;c^{w} 代表扭曲后的配对目标服装图像;m_{c} 代表未着装人物图像中对应位置的上装掩码;$c_{\mathrm{mask}}^{\mathrm{w}}$ 代表扭曲后配对目标服装图像的掩码。

2.4.2　蒸馏损失函数

本文使用相关的蒸馏损失来实现教师-学生网络之间的性能迁移。由于教师网络的金字塔特征提取器所输入的条件图像比学生网络拥有更加丰富的

中国知网　https://www.cnki.net

语义信息供服装扭曲匹配网络进行信息匹配,因此本文对 2 个网络所提取的条件图像特征应用 1 个特征蒸馏损失

$$L_{\mathrm{FKD}} = \sum_{i=1}^{5} \| \mathrm{Conv}_{1\times1}(I_i^{\mathrm{T}}) - I_i^{\mathrm{S}} \|$$

式中:L_{FKD} 代表特征蒸馏损失;I_i^{T},I_i^{S} 分别代表教师、学生服装扭曲匹配网络 WN-T,WN-S 中第 i 层条件输入的特征图;$\mathrm{Conv}_{1\times1}$ 代表 1×1 卷积操作,以实现特征维度的匹配。

此外,由于最小尺度的外观流推断无法获得来自上一尺度的外观流作为调制基准,导致服装扭曲匹配网络对较低分辨率外观流的学习准确率较低,因此本文对不同尺度的外观流应用 1 个自蒸馏损失 L_{SKD},即将所输出的精度最高的外观流视为伪标签,对不同尺度下的外观流进行自监督,但由于中间尺度的外观流估计模块能够获得来自上一尺度的输出外观流作为该尺度下的调制基准;因此本文只对模型深层输出的外观流进行自监督:

$$L_{\mathrm{SKD}} = \sum_{i=4}^{5} \psi(f_1 - f_i)$$

式中:$\psi(x) = (|x| + \xi)^q$,ξ、q 代表用于平衡该损失的超参数,分别为 0.000 001、0.45。最后为提高外观流的平滑度,防止所推断外观流场对目标服装图像采样扭曲时出现伪影和不平滑现象,本文对最终预测的外观流 f_1 应用平滑损失,该损失是广义上的 Charbonnier 损失函数[25]:

$$L_{\mathrm{S}} = \| \nabla f_1 \|_1$$

式中,L_{S} 代表平滑损失。

最后,本文对上述损失进行加权计算和:

$$L = \lambda_{\mathrm{VGG}}^{\mathrm{G}} L_{\mathrm{VGG}}^{\mathrm{G}} + \lambda_{\mathrm{L1}}^{\mathrm{w}} L_{\mathrm{L1}}^{\mathrm{w}} + \lambda_{\mathrm{FKD}} L_{\mathrm{FKD}} + \lambda_{\mathrm{SKD}} L_{\mathrm{SKD}} + \lambda_{\mathrm{S}} L_{\mathrm{S}}$$

式中:L 代表训练总损失;$\lambda_{\mathrm{VGG}}^{\mathrm{G}}$、$\lambda_{\mathrm{L1}}^{\mathrm{w}}$、$\lambda_{\mathrm{FKD}}$、$\lambda_{\mathrm{SKD}}$、$\lambda_{\mathrm{S}}$ 代表用于平衡 5 个损失数值的超参数,分别设置为 5.0、10.0、0.2、0.2、2。

3 实验结果与分析

3.1 VITON 数据集

选择 VITON 数据集[6]作为本文所提出模型的训练对象,该数据集在基于二维图像的虚拟试衣任务中被广泛使用。VITON 数据集共包含 14 221 组分辨率为 256 像素×192 像素的配对训练图像和 2 032 组相应分辨率的配对测试图像。其中,每组配对图像包含待试衣人体前景半身图像和对应目标服装图像。

3.2 实验环境及评价指标

本文实验利用深度学习框架 Pytoch 1.13.0 对模型进行实现,并将其部署于内存为 12 GB 的 Nvidia 3080GPU 上进行模型训练和测试。另外,使用 Adam 优化器作为模型优化器对服装扭曲教师网络、试衣生成教师网络、服装扭曲学生网络、试衣生成学生网络分别训练 100、150、100、100 轮,其初始学习率分别设置为 0.000 1、0.000 05、0.000 01、0.000 01,其学习率数值随迭代次数增加而线性衰减。

为衡量试衣模型的性能,本文选择 Frechet inception 距离[26](Frechet inception distance, FID)、结构相似性[27](structural similarity index measure, SSIM)、感知图像块相似度[28](learned perceptual image patch similarity, LPIPS)、内核初始距离[29](kernel inception distance, KID)、峰值信噪比[30](peak signal-to-noise ratio, PSNR)作为试衣结果图像评价的定量指标。FID 是用于度量生成图像与真实图像特征向量之间距离的计算机视觉评价指标,其结果与生成图像质量有很大的相关性,得分越低则代表生成图像质量与真实图像质量越接近。SSIM 通过对图像的照明度、结构度、对比度综合分析得出,是更符合人体视觉感官的一种图像评价指标,其数值越大则代表 2 张图像之间的差异越小。LPIPS 是用于衡量 2 张图像之间差异的评价指标,通过计算提取图像特征的欧式距离得出,数值越低,代表 2 张图像之间的相似度越高。KID 与 FID 相比是一种无偏估计,当样本量较小时,其较 FID 更具有模型描述性,更符合人类感知情况,其数值越小,代表图像之间的差异越小。PSNR 是一种基于均方误差值的图像评价指标,有效解决了均方误差值的衡量图像差异的局限性,PSNR 数值越大,则代表图像重建质量越高。

3.3 定量对比分析

为证明本文方法的有效性,本文对比了基于人体解析图像的虚拟试衣方法 CP-VTON+[31]、ACGPN[32]、RT-VTON[33]、SDAFN,以及基于无人体解析图像的虚拟试衣方法 PF-AFN、Style-VTON,其中,Style-VTON 方法在 VITON 数据集上取得了最优的结果。

3.3.1 整体图像指标评价与分析

各方法在 VITON 测试集的定量结果如表 1 所示。可以看出,本文模型在 FID、LPIPS、PSNR、KID 的评分结果均优于目前的其它模型,较目前性能较优模型 Style-VTON 分别提升 5.06%、28.57%、3.71%、33.33%。其中,用于衡量图像感知相似度的 LPIPS 和用于衡量小样本条件下模型性能的 KID 的数值提升幅度最大,说明本文方法所获得的试衣

中国知网 https://www.cnki.net

结果图像与其它方法相比,更加符合人类视觉感知。此外,用于衡量图像失真程度的 PSNR 也有一定程度的提升,证明本文方法生成的着装人物图像较其它方法更加清晰。

表 1　各方法在 VITON 测试集上的定量比较

Tab. 1　Quantitative comparison of methods on VITON test dataset

方法	FID	SSIM	LPIPS	KID/10^{-2}	PSNR
CP-VTON+	22.36	0.82	0.12	0.92	21.81
ACGPN	17.95	0.84	0.11	0.73	23.11
PF-AFN	10.09	0.89	0.06	0.21	27.25
Style-VTON	8.89	0.91	0.07	0.12	26.70
RT-VTON	11.66	—	—	—	—
SDAFN	10.42	0.87	0.08	0.16	26.48
本文模型	8.44	0.90	0.05	0.08	27.69

3.3.2　服装复杂度评价与分析

为验证本文方法对扭曲带有复杂纹理服装的效果优于其它方法,计算 VITON 测试集中所有目标服装图像的像素平均梯度,以此来表示目标服装图像的纹理复杂程度 GTC,其定义如下:

$$G_1 = \frac{\alpha \mid \mathrm{Sobel}X(cc_{\mathrm{m}}) \mid + \beta \mid \mathrm{Sobel}Y(cc_{\mathrm{m}}) \mid}{S_{\mathrm{cm}}}$$

$$G_2 = \frac{\alpha \mid \mathrm{Sobel}X(c) \mid + \beta \mid \mathrm{Sobel}Y(c) \mid}{WH}$$

$$\mathrm{GTC} = \begin{cases} G_1, \dfrac{\max(G_1, G_2)}{\min(G_1, G_2)} \geqslant \theta \\ G_2, \dfrac{\max(G_1, G_2)}{\min(G_1, G_2)} < \theta \end{cases}$$

式中:G_1 表示基于目标服装掩码区域的像素平均梯度值;G_2 表示基于图像全局区域的像素平均梯度值;α 与 β 分别表示 X、Y 方向图像梯度值的权重参数,本文分别取 0.5,0.5。W、H 分别为图像的宽和高,像素;c、c_{m} 则分别代表目标服装图像及其掩码;Sobel$X$、Sobel$Y$ 分别代表计算目标图像 X、Y 方向上的梯度值;S_{cm} 表示目标服装图像掩码 c_{m} 的面积。由于 VITON 测试集中某些目标服装掩码图像存在错误,导致其像素平均梯度计算误差较大,因此本文通过计算基于图像全局区域的像素平均梯度值 G_2,并引入梯度判断参数 θ 判断目标服装图像的复杂度,其中 θ 取 3。

本文根据服装复杂度对 VITON 测试集进行划分,考虑到样本容量的限制问题,将服装复杂度划分为 3 个分段:0~20、20~40、>40,各分段的样本数量分别为 479、1 088、453。GTC 数值与服装复杂程度呈现强烈的相关性,其数值越大,则目标服装纹理越复杂,服装复杂度也越高。最后,本文分别计算 6 种方法在不同服装复杂度分段上的图像质量评价指标数值(FID、KID、LPIPS、SSIM、PSNR),并进行相应地可视化,这 6 种方法在各服装复杂度分段的图像评价量化趋势如图 4 所示。从各指标量化柱状图中的趋势线分析可以得出,当服装复杂度越高时,各方法处理带有复杂纹理服装图像的能力就越弱。在感知图像块相似度、内核初始距离指标中,本文方法在各服装复杂度分段的表现均优于其它方法,较目前性能最优的模型分别提升 35.54%、30.41%、12.94%、48.08%、30.45%、1.03%;且在结构相似度指标中,本文方法在>40 分段的表现远优于其它方法,证明本文方法在扭曲带有复杂纹理的服装图像时,其还原、保留原始服装细节的能力要优于其它方法。

3.3.3　模型量化评价与分析

本文通过计算模型参数量与计算复杂度对各方

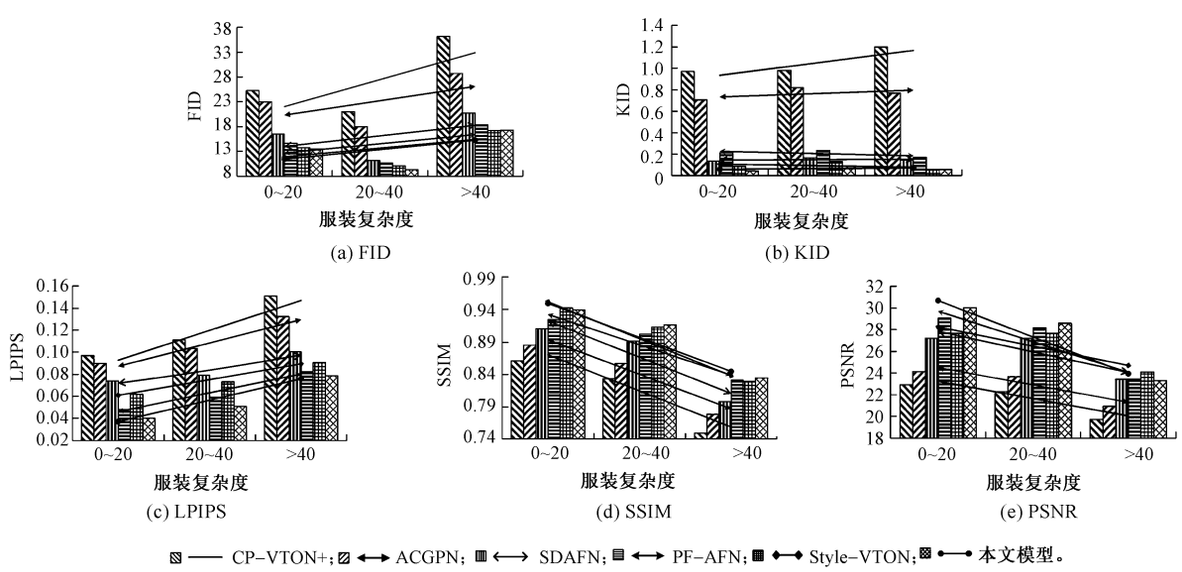

图 4　6 种方法在各服装复杂度分段的图像评价量化图

Fig. 4　Six methods in each garment complexity segmentation of image evaluation quantization map

中国知网　https://www.cnki.net

法模型的尺寸与运行速度进行相应地量化，如表 2 所示。可得，本文方法在模型参数量上均优于其它 5 种方法，计算复杂度优于除 CP-VTON+外的其它方法，证明本文模型较目前方法的整体模型尺寸更小、运行速度更快。

3.4 定性对比分析

各方法在 VITON 测试集上的定性结果见图 5。

表 2 6 种方法模型尺寸及计算复杂度比较

Tab. 2 Comparison of model size and computational complexity of six methods

方法	模型参数量/10^6	计算复杂度/10^8
CP-VTON+	40.41	136.0
ACGPN	>100	>1 000
SDAFN	37.65	747.0
PF-AFN	73.20	689.3
Style-VTON	88.41	542.9
本文模型	26.41	312.9

注：图中人物图像均来源于 VITON 数据集。

图 5 各方法在 VITON 测试集上的定性比较

Fig. 5 Qualitative comparison of methods on VITON test dataset. (a) Clothing style 1; (b) Clothing style 2; (c) Clothing style 3; (d) Clothing style 4; (e) Clothing style 5; (f) Clothing style 6

中国知网 https://www.cnki.net

分析图 5(a)、(b)得出,本文方法能够准确地匹配相应的上装位置,并完整保留下装与身体其它部位的细节。此外,在面临复杂位姿以及头发、手部遮挡时,本文方法在准确匹配对应换装位置的同时,能够最大程度上保留目标服装上的条纹细节,有效改善躯干部位的条纹挤压现象和着装人物图像中的伪影现象,如图 5(c)、(d)所示。针对带有复杂纹理的目标服装,其它方法生成的着装图像有严重的纹理丢失、像素模糊现象, 例如图 5(d)中手部遮挡的躯干部位,图 5(e)中服装左肩部位,图 5(f)中下装腰带、头发、服装领口等部位,且其它方法的纹理畸变现象十分明显,但在本文模型中,这种情况得到明显改善,证明本文方法能够更有效地处理带有复杂纹样的目标服装。

3.5　消融实验

本文分别对提出的外观流估计改进方法—外观流校准、粗糙流估计、细化流估计,以及引入的自蒸馏损失展开相应的消融实验,验证其各自的有效性。

首先,为验证本文模型中外观流校准方法和基于特征增强的外观流细化网络的有效性,在 VITON 测试集上分别进行消融实验。

各模型参数配置下的定量比较列于表 3。可以看出,外观流校准方法和基于特征增强的外观流细化方法在 3 个评价指标上均有较大幅度的提升,且当 2 种方法组合时,其评价指标数值的提升幅度最大,证明该外观流估计方法对服装扭曲匹配网络的性能提升有较为明显的作用,而服装扭曲的精度将直接影响最终的着装人物合成结果。

表 3　各模型配置下的定量比较

Tab. 3　Quantitative comparison form model configurations

模型配置	外观流校准	粗糙流估计	精细流估计	FID	KID/10^{-2}	SSIM
配置 1		√		9.62	0.115	0.891
配置 2	√	√		9.41	0.110	0.893
配置 3		√	√	8.54	0.089	0.902
配置 4	√	√	√	8.44	0.083	0.903

针对外观流校准与基于特征增强的外观流细化网络的不同模型配置的定性比较如图 6 所示,分别对应表 3 的各参数配置。

从图 6 可知,本文方法在解决伪影、配准错误、服装边缘不光滑等问题上起到明显的作用。其中基于特征增强的外观流细化方法,对服装图像扭曲精度的提升最为明显,并且外观流校准也能细化扭曲后服装边缘的不平滑现象。

其次,针对本文提出的自蒸馏方法及其损失函数展开相应的消融实验。对训练相同次数后的 2 个

注:图中人物图像均来源于 VITON 数据集。

图 6　各模型配置下的定性比较图

Fig. 6　Qualitative comparison for model configurations.

(a) Colthing style 7; (b) Clothing style 8

服装扭曲学生网络与统一的试衣生成器分别在 VITON 测试集上进行测试,其定量结果对比见表 4。可以看出,加入 L_{SKD} 后的结果图像质量指标 FID、SSIM、LPIPS、KID、PSNR 的数值均优于未加入 L_{SKD} 时的结果,证明该损失有效,且对模型性能的提升作用较为明显。

表 4　不同训练损失函数配置下的定量比较

Tab. 4　Quantitative comparison for different training loss function configurations

方法	FID	SSIM	LPIPS	KID/10^{-2}	PSNR
未加入 L_{SKD}	8.60	0.89	0.06	0.09	27.48
加入 L_{SKD}	8.44	0.90	0.05	0.08	27.69

4　结　论

本文提出一个基于混合知识蒸馏和特征增强技术的轻量级无解析式虚拟试衣网络,采用高效的外观流估计方法,减少服装扭曲过程中的配准错误以及复杂纹理丢失、畸变等现象。此外,本文通过混合知识蒸馏以及使用深度可分离卷积,减少最终模型的尺寸和计算复杂度,加快模型的运行速度。最后,本文提出用于表征服装纹理复杂程度的量化指标——服装复杂度,并对 VITON 测试集进行样本划分。与其它虚拟试衣方法的对比实验结果表明,在 VITON 测试集上,本文的各项评价指标结果均优于目前表现最优的虚拟试衣方法,并且本文方法处理带有复杂纹样服装的能力也优于其它方法。此外本文通过消融实验证明所提出的改进方法对最终的试衣结果有明显的改善作用。

但是,本文研究工作仍存在一些问题:首先,由于经过模型压缩后的学生网络需通过特征匹配对教师网络进行相应映射以实现知识迁移,该过程不可

中国知网　https://www.cnki.net

避免产生精度损失,致使无法有效迁移教师网络的性能。此外,深度可分离卷积的应用削弱了试衣生成学生网络的模型表达能力,例如皮肤区域生成质量低、服装颜色失真、人体其余部位细节丢失等现象。为此,在下一步研究中,应该对蒸馏模式和压缩模型尺寸进行进一步的优化和提升。 FZXB

参考文献:

[1] BHATNAGAR B L, TIWARI G, THEOBALT C, et al. Multi-garment net: learning to dress 3D people from images [C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. Seoul, Korea: IEEE, 2019: 5420-5430.

[2] MIR A, ALLDIECK T, PONS-MOLL G. Learning to transfer texture from clothing images to 3D humans [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, WA, USA: IEEE, 2020: 7023-7034.

[3] ZHAO F, XIE Z, KAMPFFMEYER M, et al. M3D-VTON: a monocular-to-3D virtual try-on network [C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. Montreal, Canada: IEEE, 2021: 13239-13249.

[4] DUCHON J. Splines minimizing rotation-invariant semi-norms in sobolev spaces [C]// Proceedings of the Constructive Theory of Functions of Several Variables. Berlin: Springer, 1977: 85-100.

[5] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[J]. Advances in Neural Information Processing Systems, 2014, 27(4): 2670-2680.

[6] HAN X, WU Z, WU Z, et al. Viton: an image-based virtual try-on network [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA: IEEE, 2018: 7543-7552.

[7] GONG K, LIANG X, ZHANG D, et al. Look into person: self-supervised structure-sensitive learning and a new benchmark for human parsing [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, HI, USA: IEEE, 2017: 932-940.

[8] CAO Z, SIMON T, WEI S-E, et al. Realtime multi-person 2D pose estimation using part affinity fields [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, HI, USA: IEEE, 2017: 7291-7299.

[9] HAN X, HU X, HUANG W, et al. Clothflow: a flow-based model for clothed person generation [C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. Seoul, Korea: IEEE, 2019: 10471-10480.

[10] CHOPRA A, JAIN R, HEMANI M, et al. Zflow: gated appearance flow-based virtual try-on with 3D priors [C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. Montreal, QC, Canada: IEEE, 2021: 5433-5442.

[11] LEE S, GU G, PARK S, et al. High-resolution virtual try-on with misalignment and occlusion-handled conditions [C]// Proceedings of the European Conference on Computer Vision. Tel-Aviv, Israel: Springer, 2022: 204-219.

[12] XIE Z, HUANG Z, DONG X, et al. GP-VTON: Towards general purpose virtual try-on via collaborative local-flow global-parsing learning [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, BC, Canada: IEEE, 2023: 23550-23559.

[13] BAI S, ZHOU H, LI Z, et al. Single stage virtual try-on via deformable attention flows [C]// Proceedings of the European Conference on Computer Vision. Tel-Aviv, Israel: Springer, 2022: 409-425.

[14] GE Y, SONG Y, ZHANG R, et al. Parser-free virtual try-on via distilling appearance flows [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, TN, USA: IEEE, 2021: 8485-8493.

[15] HE S, SONG Y Z, XIANG T. Style-based global appearance flow for virtual try-on [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans, LA, USA: IEEE, 2022: 3470-3479.

[16] KARRAS T, LAINE S, AILA T. A style-based generator architecture for generative adversarial networks [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, CA, USA: IEEE, 2019: 4401-4410.

[17] GÜLER R A, NEVEROVA N, KOKKINOS I. Densepose: ense human pose estimation in the wild [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA: IEEE, 2018: 7297-7306.

[18] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, HI, USA: IEEE, 2017: 2117-2125.

[19] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation [C]// Proceedings of the Medical Image Computing and Computer-Assisted Intervention: MICCAI 2015. Munich, Germany: Springer, 2015: 234-241.

[20] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE, 2016: 770-778.

[21] CHOLLET F. Xception: deep learning with depthwise separable convolutions [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, HI, USA: IEEE, 2017: 1251-1258.

[22] SANDLER M, HOWARD A, ZHU M, et al. Mobilenetv2: inverted residuals and linear bottlenecks [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA: IEEE, 2018: 4510-4520.

[23] JOHNSON J, ALAHI A, FEI-FEI L. Perceptual losses

中国知网 https://www.cnki.net

for real-time style transfer and super-resolution [C]// Proceedings of the Computer Vision: ECCV 2016. Amsterdam, The Netherlands: Springer, 2016: 694-711.

[24] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. Computer Science, 2014. DOI: 10.48550/arXiv.1409.1556.

[25] SUN D, ROTH S, BLACK M J. A quantitative analysis of current practices in optical flow estimation and the principles behind them [J]. International Journal of Computer Vision, 2014(106): 115-137.

[26] HEUSEL M, RAMSAUER H, UNTERTHINER T, et al. Gans trained by a two time-scale update rule converge to a local nash equilibrium[J]. Advances in Neural Information Processing Systems, 2017 (30): 6626-6637.

[27] WANG Z, BOVIK A C, SHEIKH H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.

[28] ZHANG R, ISOLA P, EFROS A A, et al. The unreasonable effectiveness of deep features as a perceptual metric [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA: IEEE, 2018: 586-595.

[29] SUTHERLAND J D, ARBEL M, GRETTON A. Demystifying mmd gans [C]// International Conference on Learning Representations. Vancouver, Canada: ICLR, 2018: 1-36.

[30] HORE A, ZIOU D. Image quality metrics: PSNR vs. SSIM [C]// Proceedings of the 2010 20th International Conference on Pattern Recognition. Istanbul, Turkey: IEEE, 2010: 2366-2369.

[31] MINAR M R. TUAN T T, AHN H, et al. Cp-vton+: clothing shape and texture preserving image-based virtual try-on [C]// Proceedings of the CVPR Workshops. Seattle, WA, USA: IEEE, 2020: 10-14.

[32] YANG H, ZHANG R, GUO X, et al. Towards photo-realistic virtual try-on by adaptively generating-preserving image content [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, WA, USA: IEEE, 2020: 7850-7859.

[33] YANG H, YU X, LIU Z. Full-range virtual try-on with recurrent tri-level transform [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans, LA, USA: IEEE, 2022: 3460-3469.

Lightweight parser-free virtual try-on based on mixed knowledge distillation and feature enhancement techniques

HOU Jue[1,2], DING Huan[1], YANG Yang[1,2], LU Yinwen[1], YU Lingjie[3], LIU Zheng[2,4]

(1. *School of Fashion Design & Engineering*, *Zhejiang Sci-Tech University*, *Hangzhou*, *Zhejiang* 310018, *China*; 2. *Key Laboratory of Silk Culture Inheritance and Digital Technology of Product Design*, *Ministry of Culture and Tourism*, *Hangzhou*, *Zhejiang* 310018, *China*; 3. *School of Textile Science and Engineering*, *Xi'an Polytechnic University*, *Xi'an*, *Shaanxi* 710048, *China*; 4. *International Institute of Fashion Technology*, *Zhejiang Sci-Tech University*, *Hangzhou*, *Zhejiang* 310018, *China*)

Abstract

Objective In order to address the issues of low accuracy in clothing deformation, texture distortion, and high computational costs in image-based virtual try-on systems, this paper proposes a lightweight parser-free virtual try-on based on mixed knowledge distillation and feature enhancement techniques.

Method Firstly, by integrating global features and calibrating the results of flow computation at different scales, an improved appearance flow estimation method was proposed to enhance the accuracy of appearance flow estimation. Moreover, a lightweight try-on network based on depth separable convolution was constructed by decoupling image segmentation results and virtual try-on processes using knowledge distillation. Finally, a garment complexity index GTC (garment texture complexity) based on the pixel-wise average gradient was proposed to quantitatively analyze the texture complexity of clothing. Based on this, the VITON dataset is divided into a simple texture set, a moderately complex texture set, and a highly complex texture set.

Results This paper used the VITON dataset to verify and analyze the proposed model. Compared with the SOTA (state-of-art) model, the number of parameters and computational complexity (flops) was decreased by 70.12% and 42.38%, respectively, suggesting a faster and better model to meet the deployment requirements of the mobile Internet. Moreover, the experimental results showed that the scores of the proposed model in image quality evaluation indicators (FID, LPIPS, PSNR, KID) were increased by 5.06%, 28.57%, 3.71%, and 33.33%, respectively, compared with the SOTA model. In the segmentation analysis of clothing complexity, the score of KID and LPIPS in this model was 48.08%, 30.45%, 1.03%, 35.54%, 30.41%, and 12.94% higher

中国知网 https://www.cnki.net

than that of the SOTA model, respectively, proving that the method proposed is superior to other methods in restoring and preserving original clothing details when warping clothing images with complex textures.

Conclusion A lightweight parser-free virtual try-on based on mixed knowledge distillation and feature enhancement techniques is proposed, which uses an efficient appearance flow estimation method to reduce registration errors, complex texture loss, and distortion during the clothing distortion process. In addition, the method proposed is shown to reduce the size and computational complexity of the final model by mixing distillation and using depth-separable convolution effectively and speeding up the running of the model. Finally, a quantitative index used for characterizing the complexity of clothing texture is proposed and the VITON test set is divided into samples. Compared with other virtual try-on methods, the experimental results show that on the VITON test set, the evaluation index results obtained from the proposed method are better than the current virtual try-on method with the best performance, and the ability of the proposed method to deal with clothing with complex patterns is also better than other methods. In addition, the ablation experiment proves that the proposed method has an obvious improvement on the final virtual try-on result.

Keywords virtual try-on; appearance flow; knowledge distillation; feature enhancement technique; garment texture complexity; apparel e-commerce

中国知网 https://www.cnki.net